

6.18 研究日志新版：OT 方法、新版 Cross-cell 与 Legacy EI 结果

以 6.15 符号体系为基础，补充 OT 细节、重写新版 cross-cell 网络机制，并更新 result6.18 的 Legacy EI 结果

2026 因果涌现项目 Vertical MIGNet Ablation

本版修改重点

本版报告在原 6.18 诊断稿基础上做三件事。第一，沿用 6.15 研究日志中的符号系统，把 OT 家族的 C_{ij} 、 T_{ij} 、 P_{ij} 从“概念描述”改成“逐步构造”的说明：先说明 source unit 和 target unit 的网络特征如何进入 cost，再说明 entropic OT 如何得到 transport plan，最后说明为什么 EI/DI 使用的是行归一化后的 transition kernel。第二，根据当前 code.zip 中的新版 cross_cell_multilayer.py，把 cross-cell 网络从旧的“十四维统计量压缩”改写为“target-aware multichannel upper-coordinate representation”，并明确说明 DDI 在新版中已经不再单独重复建模。第三，重新读取 result6.18.zip 中 legacy_mixed_grn_cci 网络的外围 metrics.csv，只更新与 EI 和 EI_gain 有关的结果表；cross-cell 网络相关结果表本版不再展开。

1 报告坐标系：什么是 source、target、lower 和 upper

本报告讨论的对象仍然是 vertical ablation。设当前比较的是一个从 lower layer 到 upper layer 的层级对。lower layer 是较细的空间层级，例如 spot、less-than5 或 k150；upper layer 是较粗的空间层级，例如 less-than5、k150 或 k40。为了避免符号混乱，本报告继续沿用 6.15 的写法：当前时间点记为 t ，后一时间点记为 t' 。在时间点 t 上的 source unit 用 i 表示，在时间点 t' 上的 target unit 用 j 表示。

设时间点 t 的 source units 数量为 n ，时间点 t' 的 target units 数量为 m 。跨时间转移矩阵记为

$$P^{t \rightarrow t'} = \begin{bmatrix} P_{11} & P_{12} & \cdots & P_{1m} \\ P_{21} & P_{22} & \cdots & P_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ P_{n1} & P_{n2} & \cdots & P_{nm} \end{bmatrix}, \quad \sum_{j=1}^m P_{ij} = 1.$$

这里 $P^{t \rightarrow t'}$ 表示从时间点 t 到时间点 t' 的条件转移概率矩阵； P_{ij} 表示“给定第 i 个 source unit 后，它在后一时间点对应到第 j 个 target unit 的概率”；每一行加和为 1，表示每个 source unit 的概率质量被分配到所有 target units 上。

对网络结构来说，每个 unit 首先会被表示为网络特征向量。时间点 t 中第 i 个 unit 的网络特征记为

$$\mathbf{z}_i^t \in \mathbb{R}^d.$$

这里 $\mathbf{z}_i^t$ 是第 i 个 unit 在时间点 t 的 GRN/CCI 综合状态， d 是特征维度。OT 方法并不直接看原始 count，而是看网络结构模块输出后、再经过聚合、降维和缩放的 feature vector。因此 OT 中的“表达相似”更准确地说是“网络特征相似”或“网络状态相似”。

2 6.15 中 OT 方法需要补清楚的核心逻辑

2.1 OT 在 vertical ablation 里到底解决什么问题

在胚胎发育数据中，时间点 t 的 unit 和时间点 t' 的 unit 之间没有天然一一对应关系。OT 方法把这个问题看成“把前一时间点的 unit 质量搬运到后一时间点的 unit 上”。对于任意 source unit i 和 target unit j ，先定义一个代价

$$C_{ij}.$$

这里 C_{ij} 表示“把第 i 个 source unit 匹配到第 j 个 target unit 有多不合适”。 C_{ij} 越小，说明 source unit i 和 target unit j 越应该对应； C_{ij} 越大，说明这个对应越不自然。不同 OT 方法的区别，主要就在于 C_{ij} 是怎样由表达、网络特征、空间坐标、发育伪时、SR、potency 或 velocity 共同构造出来的。

有了代价矩阵 $C \in \mathbb{R}^{n \times m}$ 后，OT 不会对每个 i 单独贪心选择最像的 j ，而是在全局约束下寻找一个 transport plan:

$$T \in \mathbb{R}_{\geq 0}^{n \times m}.$$

这里 T_{ij} 表示“从第 i 个 source unit 运到第 j 个 target unit 的质量”。 T_{ij} 不是最终直接进入 EI 的条件概率，因为 balanced OT 中每一行的总质量通常被约束为 $1/n$ ，不是 1。真正进入 EI/DI/TE-like 指标的是行归一化后的概率矩阵 P ，也就是

$$P_{ij} = \frac{T_{ij}}{\sum_{k=1}^m T_{ik}}.$$

这里 P_{ij} 才是“给定 source unit i 后，target unit 为 j 的条件概率”。因此 OT 方法的完整链条是

$$\mathbf{z}_i^t, \mathbf{z}_j^{t'} \longrightarrow C_{ij} \longrightarrow T_{ij} \longrightarrow P_{ij}.$$

2.2 进入 OT 前的网络特征如何对齐

当前代码的 OT 方法共用一个 feature preparation 过程。对每一个时间点，lower layer 的原始网络特征会先通过 lower-to-upper overlap 聚合到 stable upper unit 坐标上；upper layer 的网络特征也会按照 stable upper unit 的顺序对齐。设时间点 t 的 lower unit feature matrix 为 X_{lower}^t ，时间点 t 的 upper unit feature matrix 为 X_{upper}^t 。代码会把 lower 侧先变成 upper 坐标中的表示：

$$\hat{X}_{\text{lower}}^t = \text{Aggregate}(X_{\text{lower}}^t, W^t).$$

这里 W^t 是时间点 t 的 lower-to-upper overlap 权重矩阵； $\hat{X}_{\text{lower}}^t$ 表示 lower layer 的信息已经被汇总到 stable upper units 这一共同坐标上。upper 侧则做顺序对齐：

$$\hat{X}_{\text{upper}}^t = \text{Align}(X_{\text{upper}}^t, \mathcal{U}_{\text{stable}}).$$

这里 $\mathcal{U}_{\text{stable}}$ 是所有时间点上 stable upper units 的统一集合。之后所有时间点的 lower features 和 upper features 会进入同一个降维和全局缩放过程，得到最终用于 OT 的 $\mathbf{z}_i^t$ 和 $\mathbf{z}_j^{t'}$ 。这一步很关键：它保证不同时间点的 feature 坐标可比较，也保证 lower 和 upper 的 EI 可以在同一套 transition 构造逻辑下比较。

2.3 共同底层：从 cost matrix 到 entropic OT

设 source 时间点有 n 个 units, target 时间点有 m 个 units。当前实现默认给每个 source unit 相同的待运输质量, 也给每个 target unit 相同的接收质量:

$$a_i = \frac{1}{n}, \quad b_j = \frac{1}{m}.$$

这里 a_i 是第 i 个 source unit 拥有的质量, b_j 是第 j 个 target unit 希望接收的质量。均匀边际的含义是: 在没有额外 size 权重时, 每个 unit 被同等对待。

balanced entropic OT 要求 transport plan T 满足 source 和 target 两侧的边际约束:

$$\sum_{j=1}^m T_{ij} = a_i, \quad \sum_{i=1}^n T_{ij} = b_j, \quad T_{ij} \geq 0.$$

这里 $\sum_j T_{ij} = a_i$ 表示第 i 个 source unit 的全部质量都被送出; $\sum_i T_{ij} = b_j$ 表示第 j 个 target unit 接收到指定质量。熵正则目标写作

$$\min_{T \geq 0} \sum_{i=1}^n \sum_{j=1}^m T_{ij} C_{ij} + \varepsilon \sum_{i=1}^n \sum_{j=1}^m T_{ij} (\log T_{ij} - 1).$$

这里第一项 $\sum_{ij} T_{ij} C_{ij}$ 是总运输代价, 表示“质量越多地流向高代价匹配, 整体越差”; 第二项是熵正则项, ε 是熵正则强度。 ε 越大, transport plan 越平滑; ε 越小, transport plan 越集中在少数低代价匹配上。

代码先把代价转换成 Sinkhorn kernel:

$$K_{ij} = \exp\left(-\frac{C_{ij}}{\varepsilon}\right).$$

这里 K_{ij} 是由代价产生的初始匹配倾向。 C_{ij} 越小, K_{ij} 越大; C_{ij} 越大, K_{ij} 越接近 0。随后用两个缩放向量 u 和 v 调整 source 和 target 的边际:

$$T_{ij} = u_i K_{ij} v_j.$$

这里 u_i 是第 i 个 source unit 的行缩放因子, v_j 是第 j 个 target unit 的列缩放因子。Sinkhorn 迭代不断更新 u 和 v , 直到 T 同时满足 source 质量和 target 质量约束。最后输出的转移矩阵仍然是

$$P_{ij} = \frac{T_{ij}}{\sum_{k=1}^m T_{ik}}.$$

所以, 对后续 EI 来说, OT 的作用不是直接给一个相似度矩阵, 而是先在全局 mass competition 中得到 T , 再把 T 变成条件概率 P 。

2.4 unbalanced OT 的含义

如果配置中打开 unbalanced OT, 则边际约束不再被严格满足, 而是变成软约束。直观地说, balanced OT 强制 source 的总质量完全搬到 target, 并且每个 target 接收相同质量; unbalanced OT 允许部分 source 或 target 的质量被放松。代码中 unbalanced 的调节参数记为 ρ , 也就是配置里的 mass regularization。 ρ 越大, 越接近 balanced OT; ρ 越小, 越允许质量不完全匹配。但无论 balanced 还是 unbalanced, 最后都会再次行归一化得到 P_{ij} , 因为 EI 需要的是条件转移概率, 而不是未归一化质量。

3 各个 OT 方法的详细解释

3.1 Expr OT: 只用网络特征差异构造代价

expr_ot 是最基础的 OT。虽然名字叫 expression OT，但在当前 vertical pipeline 中，它使用的是网络结构模块已经生成的 feature vector。设时间点 t 的第 i 个 source unit 的特征为 $\mathbf{z}_i^t$ ，时间点 t' 的第 j 个 target unit 的特征为 $\mathbf{z}_j^{t'}$ 。如果使用 cosine distance，特征代价写作

$$C_{ij}^{\text{expr}} = \text{Normalize} \left(1 - \frac{\mathbf{z}_i^t \cdot \mathbf{z}_j^{t'}}{\|\mathbf{z}_i^t\|_2 \|\mathbf{z}_j^{t'}\|_2} \right).$$

这里 C_{ij}^{expr} 是 source unit i 与 target unit j 的网络特征代价； $\mathbf{z}_i^t \cdot \mathbf{z}_j^{t'}$ 是两个特征向量的内积； $\|\mathbf{z}_i^t\|_2$ 和 $\|\mathbf{z}_j^{t'}\|_2$ 是两个特征向量的二范数； $\text{Normalize}(\cdot)$ 表示把代价矩阵按有限值的最小值和最大值缩放到 $[0, 1]$ 。如果两个 unit 的网络状态方向相近，cosine similarity 接近 1， C_{ij}^{expr} 就接近 0；如果两个 unit 的网络状态方向差异很大， C_{ij}^{expr} 就更大。

得到 C_{ij}^{expr} 后，expr_ot 直接把它作为总代价：

$$C_{ij} = C_{ij}^{\text{expr}}.$$

这里 C_{ij} 是进入 Sinkhorn 的最终 cost matrix。之后的步骤就是共同底层： $C_{ij} \rightarrow K_{ij} \rightarrow T_{ij} \rightarrow P_{ij}$ 。

3.2 Energy-entropy OT: 在网络特征之外加入空间和 graph energy

energy_entropy_ot 与 expr_ot 共用 entropic OT 求解器，但它的 cost 由多个 component 组成。第一部分仍然是网络特征代价 C_{ij}^{expr} 。第二部分是空间代价。设 source unit i 在时间点 t 的空间坐标为 $\mathbf{r}_i^t$ ，target unit j 在时间点 t' 的空间坐标为 $\mathbf{r}_j^{t'}$ ，空间代价为

$$C_{ij}^{\text{spatial}} = \text{Normalize} \left(\left\| \mathbf{r}_i^t - \mathbf{r}_j^{t'} \right\|_2 \right).$$

这里 C_{ij}^{spatial} 表示 source unit i 和 target unit j 在空间位置上的距离代价； $\mathbf{r}_i^t$ 和 $\mathbf{r}_j^{t'}$ 是二维或三维坐标； $\left\| \mathbf{r}_i^t - \mathbf{r}_j^{t'} \right\|_2$ 是欧氏距离。空间距离越近，空间代价越低。

第三部分是 graph energy cost。当前代码把 feature vector 的长度作为 graph energy proxy。设

$$E_i^t = \left\| \mathbf{z}_i^t \right\|_2, \quad E_j^{t'} = \left\| \mathbf{z}_j^{t'} \right\|_2.$$

这里 E_i^t 是 source unit i 的网络状态强度代理量，不是物理能量； $E_j^{t'}$ 是 target unit j 的网络状态强度代理量。graph energy 代价写作

$$C_{ij}^{\text{energy}} = \text{Normalize} \left(\left| E_i^t - E_j^{t'} \right| \right).$$

这里 C_{ij}^{energy} 表示两个 unit 的整体网络强度是否接近。如果两个 unit 的 feature norm 相近， C_{ij}^{energy} 较低；如果一个 unit 网络活性很强而另一个很弱，代价较高。

三个 component 按权重合成最终 cost：

$$C_{ij} = \frac{\alpha C_{ij}^{\text{expr}} + \beta C_{ij}^{\text{spatial}} + \gamma C_{ij}^{\text{energy}}}{\alpha + \beta + \gamma}.$$

这里 α 是网络特征代价的权重， β 是空间代价的权重， γ 是 graph energy 代价的权重。当前默认配置中， $\alpha = 1.0$ ， $\beta = 0.2$ ， $\gamma = 0.2$ 。这个方法的含义是：一个合理的跨时间匹配不但应该网络状态相似，还应该空间位置不过分跳跃，并且总体网络活性不要差异过大。

3.3 Developmental feature loader: 发育特征如何进入 OT

pseudotime_ot、sr_ot、velocity_ot 和 development_ot 都依赖外部发育特征表。对某个 layer、organ 和 stage，发育特征表的基本形式可以写成

$$Q^t = [q_{u,a}^t].$$

这里 Q^t 是时间点 t 的发育特征表， u 表示某个 unit， a 表示某一系列发育特征，例如 pseudotime、SR、potency score 或 velocity dimension。每个表至少需要有 unit identity，后续代码会按照当前 layer 的 unit 顺序把发育特征对齐。

如果当前层级没有 domain-level 发育特征表，代码可以读取 spot-level 发育特征，再通过 spot-domain map 聚合到 domain。设 domain D 包含的 spot 集合为 S_D ，spot s 的某个发育标量为 q_s ，domain 的聚合发育特征写成

$$q_D = \frac{1}{|S_D|} \sum_{s \in S_D} q_s.$$

这里 q_D 是 domain D 的发育特征， $|S_D|$ 是 domain D 中 spot 的数量， q_s 是 spot s 的原始发育特征。这个公式表示：domain 的 pseudotime、SR 或 potency score 是其内部 spots 的平均状态。若发育特征缺失，当前配置可以选择报错、均值填补或记录 warning；为了避免悄悄跑出不可解释结果，默认应倾向报错。

3.4 Pseudotime OT: 表达相似且发育进度合理

pseudotime_ot 要求 source 和 target 的发育特征表中都有 pseudotime 列。设 source unit i 在时间点 t 的 pseudotime 为 p_i^t ，target unit j 在时间点 t' 的 pseudotime 为 $p_j^{t'}$ 。pseudotime 代价写作

$$C_{ij}^{\text{pt}} = \text{Normalize} \left(\left| p_i^t - p_j^{t'} \right| \right).$$

这里 C_{ij}^{pt} 表示 source unit i 与 target unit j 的发育进度差异； p_i^t 和 $p_j^{t'}$ 是两个 unit 的伪时标量。差值越小，说明两个 unit 处于更接近的发育进度，代价越低。

如果配置中打开 backward pseudotime penalty，还会加入倒流惩罚：

$$C_{ij}^{\text{back}} = \max \left(0, p_i^t - p_j^{t'} \right).$$

这里 C_{ij}^{back} 只惩罚 source pseudotime 大于 target pseudotime 的情况。直观解释是：如果 source 已经处于更晚发育状态，而 target 却更早，那么这个跨时间匹配像是在“倒退”，应该被提高代价。

最终 cost 写作

$$C_{ij} = \frac{w_{\text{expr}} C_{ij}^{\text{expr}} + w_{\text{pt}} C_{ij}^{\text{pt}} + w_{\text{back}} C_{ij}^{\text{back}}}{w_{\text{expr}} + w_{\text{pt}} + w_{\text{back}}}.$$

这里 w_{expr} 是网络特征相似性的权重， w_{pt} 是伪时接近性的权重， w_{back} 是倒流惩罚的权重。如果 $w_{\text{back}} = 0$ ，方法只要求 pseudotime 接近；如果 $w_{\text{back}} > 0$ ，方法还会显式压制发育方向倒退。

3.5 SR OT: 表达相似且分化潜能或信号熵接近

sr_ot 首先寻找 SR 列；如果没有 SR 列，则寻找 potency score 列。设被选中的标量发育特征记为 s 。source unit i 的值为 s_i^t ，target unit j 的值为 $s_j^{t'}$ ，对应代价为

$$C_{ij}^{\text{sr}} = \text{Normalize} \left(\left| s_i^t - s_j^{t'} \right| \right).$$

这里 C_{ij}^{sr} 表示两个 unit 在 SR 或 potency score 上的差异； s_i^t 可以表示 signaling entropy rate，也可以表示分化潜能； $s_j^{t'}$ 是后一时间点 target unit 的对应值。差值越小，说明两个 unit 的潜能状态或信号熵状态越接近。

如果配置中打开 reverse potency penalty，代码会加入

$$C_{ij}^{\text{rev}} = \max(0, s_j^{t'} - s_i^t).$$

这里 C_{ij}^{rev} 惩罚 target 的潜能高于 source 的情况。它背后的假设是：发育过程中潜能通常下降，所以后一时间点不应比前一时间点更“未分化”。但是这个假设并不一定对所有器官、所有阶段都成立，因此该项应该作为消融权重，而不是无条件写死。

SR OT 的总代价可写作

$$C_{ij} = \frac{w_{\text{expr}}C_{ij}^{\text{expr}} + w_{\text{sr}}C_{ij}^{\text{sr}} + w_{\text{rev}}C_{ij}^{\text{rev}}}{w_{\text{expr}} + w_{\text{sr}} + w_{\text{rev}}}.$$

这里 w_{sr} 是 SR 或 potency 接近性的权重， w_{rev} 是反向潜能惩罚的权重。该方法适合测试“跨时间匹配是否应该尊重分化潜能连续性”。

3.6 Velocity OT: source 的动态方向是否指向 target

velocity_ot 要求 source 发育特征表中存在 velocity columns，并且 velocity vector 的维度必须与网络特征向量 $\mathbf{z}_i^t$ 的维度一致。设 source unit i 的 velocity vector 为

$$\mathbf{v}_i^t \in \mathbb{R}^d.$$

这里 $\mathbf{v}_i^t$ 表示 source unit i 在特征空间中的未来变化方向， d 与网络特征 $\mathbf{z}_i^t$ 的维度相同。source unit i 到 target unit j 的实际跨时间差向量为

$$\Delta_{ij} = \mathbf{z}_j^{t'} - \mathbf{z}_i^t.$$

这里 Δ_{ij} 表示如果从 source unit i 移动到 target unit j ，网络状态需要改变的方向。velocity direction cost 写作

$$C_{ij}^{\text{vel}} = \text{Normalize} \left(1 - \frac{\mathbf{v}_i^t \cdot \Delta_{ij}}{\|\mathbf{v}_i^t\|_2 \|\Delta_{ij}\|_2} \right).$$

这里 C_{ij}^{vel} 表示 source unit 的动态方向和 target 差向量是否一致。如果 $\mathbf{v}_i^t$ 与 Δ_{ij} 方向一致，cosine similarity 接近 1，代价接近 0；如果二者方向相反，代价较高。

Velocity OT 的总代价写作

$$C_{ij} = \frac{w_{\text{expr}}C_{ij}^{\text{expr}} + w_{\text{vel}}C_{ij}^{\text{vel}}}{w_{\text{expr}} + w_{\text{vel}}}.$$

这里 w_{vel} 是 velocity direction 的权重。这个方法比普通相似度更强，因为它不是只问“source 和 target 像不像”，而是问“source 的变化方向是否真的指向 target”。

3.7 Development OT: 把表达、空间、伪时、潜能和速度合成一个发育约束

development_ot 是综合版。它至少包含表达/网络特征代价 C_{ij}^{expr} ，并且可以根据权重打开空间、pseudotime、SR、potency、velocity、backward pseudotime 和 reverse potency。为了统一表

示，设所有启用的 cost components 组成集合 $\mathcal{A}$ 。对每个 component $a \in \mathcal{A}$ ，对应代价为 $C_{ij}^{(a)}$ ，对应权重为 w_a 。总代价写作

$$C_{ij} = \frac{\sum_{a \in \mathcal{A}} w_a \text{Normalize} \left(C_{ij}^{(a)} \right)}{\sum_{a \in \mathcal{A}} w_a}.$$

这里 $\mathcal{A}$ 是当前真正启用的 cost component 集合； $C_{ij}^{(a)}$ 是第 a 种约束对 source unit i 和 target unit j 给出的代价； w_a 是第 a 种约束的权重。某个权重为 0 时，该 component 不参与；某个权重大于 0 但必需的发育特征列缺失时，代码应直接报错。

Development OT 的定位

development_ot 不是一个新的单一生物学假设，而是一个可配置的综合假设。它可以回答：“如果我们同时要求网络状态相似、空间不要跳太远、发育进度合理、分化潜能连续，并且 source 的 velocity 方向指向 target，那么跨时间转移 P_{ij} 会不会比普通 feature OT 更清晰？”因此它适合作为后续 full ablation 中的综合方法，而不是替代所有单独 OT 方法。

4 新版 Cross-cell Multilayer: 从十四维统计量到 target-aware multichannel

4.1 旧版问题：为什么十四维统计量不适合当前 EI 问题

原 6.18 诊断稿中指出，旧版 cross-cell 网络把每个 unit 压成固定十四维统计量，包括内部调控强度、发送强度、接收强度、通信熵、top-k 强度和 DDI 统计量。这种表示的问题不是“没有生物意义”，而是它更像在回答

unit i 总体有多活跃？

而 vertical ablation 的 EI 问题更需要回答

unit i 的作用到底指向哪个 upper unit？

如果两个 lower units 都有很高的 out strength，它们在十四维统计量里可能很像；但如果一个主要指向 upper unit 1，另一个主要指向 upper unit 8，它们在 vertical emergence 中的意义其实完全不同。新版 cross-cell 正是围绕这个问题做了修改。

4.2 stable upper units: 新版 cross-cell 的共同坐标轴

设当前 vertical pair 的 upper layer 在所有时间点上出现过的 upper units 组成稳定集合

$$\mathcal{U}_{\text{stable}} = \{u_1, u_2, \dots, u_K\}.$$

这里 $\mathcal{U}_{\text{stable}}$ 是 stable upper units 的集合， u_k 是第 k 个 upper unit， K 是 stable upper units 的数量。新版 cross-cell 的每个特征通道都以 u_1 到 u_K 为坐标。因此它不再是固定十四维，而是四个通道各有 K 维，总维度为

$$d_{\text{cross}} = 4K.$$

这里 d_{cross} 是新版 cross-cell 输出的 feature dimension, $4K$ 中的 4 对应四个 target-aware blocks: GRN target block、CCI out target block、CCI in source block 和 LR target block。

当前时间点的 lower unit 仍记为 $i = 1, 2, \dots, n_o$ 。lower unit 与 stable upper unit 之间的归属关系由 overlap 权重矩阵表示：

$$W_{i,k}.$$

这里 $W_{i,k}$ 表示第 i 个 lower unit 属于第 k 个 stable upper unit 的程度。它来自 spot overlap，而不是重新发明一个新层级。对 lower layer, W 是真正的 overlap matrix；对 upper layer, 代码使用 identity projection，也就是如果当前 upper unit 正好是 stable upper unit u_k ，则权重为 1，否则为 0。

4.3 共享基因与 GRN 权重：先保证表达空间可比较

新版 cross-cell 首先在所有时间点、lower layer 和 upper layer 的表达矩阵之间取共享表达基因集合。这个集合记为

$$\mathcal{G}_{\text{shared}}.$$

这里 $\mathcal{G}_{\text{shared}}$ 表示当前 vertical pair 中各时间点、各层级共同拥有的表达基因集合。之后 GRN 边只保留 regulator 和 target 都位于 $\mathcal{G}_{\text{shared}}$ 中的边。若 GRN 中一条边从基因 g 指向基因 h ，它的原始权重经过 min-max scaling 后记为

$$\tilde{w}_{g,h}.$$

这里 $\tilde{w}_{g,h}$ 是归一化后的 GRN 权重，值越大表示这条调控边在 GRN 中越强。归一化的目的不是改变边的排序，而是让不同样本、不同层级的边权处在更可比较的数值范围。

4.4 通道一：GRN target block，把内部调控活性写入 upper 坐标

设第 i 个 unit 对基因 g 的表达量为 $x_{i,g}$ ，对基因 h 的表达量为 $x_{i,h}$ 。表达阈值记为 τ 。如果 $x_{i,g} > \tau$ 且 $x_{i,h} > \tau$ ，说明在 unit i 中 regulator gene g 与 target gene h 都处于活跃状态。新版 cross-cell 的内部 GRN 活性为

$$R_i = \sum_{g \rightarrow h} \tilde{w}_{g,h} x_{i,g} x_{i,h} \mathbf{1}[x_{i,g} > \tau] \mathbf{1}[x_{i,h} > \tau].$$

这里 R_i 表示第 i 个 unit 的内部 GRN self activity； $\tilde{w}_{g,h}$ 是基因 g 到基因 h 的归一化调控权重； $x_{i,g}$ 和 $x_{i,h}$ 是第 i 个 unit 中两个基因的表达量； $\mathbf{1}[\cdot]$ 是指示函数，条件成立时为 1，否则为 0。

然后， R_i 不再作为一个总强度孤立保存，而是投影到 stable upper unit 坐标：

$$Z_{i,k}^{\text{grn_target}} = R_i W_{i,k}, \quad k = 1, 2, \dots, K.$$

这里 $Z_{i,k}^{\text{grn_target}}$ 表示第 i 个 unit 的内部调控活性中，有多少被写到第 k 个 stable upper unit 的坐标上； $W_{i,k}$ 表示 unit i 对 upper unit u_k 的归属权重。这个通道回答的是：第 i 个 unit 的内部调控活性属于哪个 upper region。

4.5 通道二：CCI out target block，把发送通讯写到目标 upper 坐标

设当前层级已经有 CCI 矩阵

$$C = [C_{i,j}] \in \mathbb{R}_{\geq 0}^{n \times n}.$$

这里 $C_{i,j}$ 表示第 i 个 unit 向第 j 个 unit 发送的总 communication strength。代码会优先读取 total CCI matrix；如果没有 total matrix，就把 COMMOT 的 ligand-receptor matrices 聚合成总 CCI。低于阈值的边会被置零，自环也会被去掉。

发送通道写作

$$Z_{i,k}^{\text{cci_out_target}} = \sum_{j=1}^n C_{i,j} W_{j,k}.$$

这里 $Z_{i,k}^{\text{cci_out_target}}$ 表示第 i 个 unit 发出的通讯最终落到第 k 个 stable upper unit 的总强度； $C_{i,j}$ 是从 source unit i 到 receiving unit j 的通讯强度； $W_{j,k}$ 表示 receiving unit j 属于 upper unit u_k 的程度。注意这里用的是 $W_{j,k}$ ，因为发送通道关心的是信号发向谁，而不是 sender 自己属于哪里。

用矩阵形式写，整个 CCI out target block 是

$$Z^{\text{cci_out_target}} = CW.$$

这里 $Z^{\text{cci_out_target}}$ 是所有 units 的发送靶向特征矩阵， C 是 unit-to-unit CCI 矩阵， W 是 unit-to-stable-upper projection matrix。

4.6 通道三：CCI in source block，把接收来源写到来源 upper 坐标

接收通道不是简单记录第 i 个 unit 收到了多少信号，而是记录这些信号主要来自哪些 upper regions。公式为

$$Z_{i,k}^{\text{cci_in_source}} = \sum_{j=1}^n C_{j,i} W_{j,k}.$$

这里 $Z_{i,k}^{\text{cci_in_source}}$ 表示第 i 个 unit 接收到的通讯中，有多少来自第 k 个 stable upper unit； $C_{j,i}$ 表示第 j 个 unit 向第 i 个 unit 发送的通讯强度； $W_{j,k}$ 表示 sender unit j 属于 stable upper unit u_k 的程度。因此这个通道回答的是：第 i 个 unit 的输入信号主要来自哪个上层区域。

矩阵形式为

$$Z^{\text{cci_in_source}} = C^T W.$$

这里 C^T 是 CCI 矩阵的转置，表示把“谁发给谁”的方向反过来用于汇总接收来源； W 仍然是 unit-to-stable-upper projection matrix。

4.7 通道四：LR target block，把 ligand-receptor 影响写到目标 upper 坐标

新版 cross-cell 仍然保留 ligand-receptor 级别的信息。设 ligand gene 为 ℓ ，receptor gene 为 r 。COMMOT 给出由 ligand ℓ 和 receptor r 介导的 unit-to-unit matrix，记作

$$C_{i,j}^{(\ell,r)}.$$

这里 $C_{i,j}^{(\ell,r)}$ 表示第 i 个 unit 到第 j 个 unit 之间由 ligand-receptor pair (ℓ, r) 介导的通讯强度。第 i 个 source unit 中 ligand ℓ 的表达量为 $x_{i,\ell}$ ，第 j 个 target unit 中 receptor r 的表达量为 $x_{j,r}$ 。如果暂时不使用 GRN gate，则单条 LR influence score 为

$$S_{i,j}^{(\ell,r)} = C_{i,j}^{(\ell,r)} x_{i,\ell} x_{j,r}.$$

这里 $S_{i,j}^{(\ell,r)}$ 表示 LR 通讯分数、ligand 表达和 receptor 表达共同支持下的跨 unit 影响强度。它比单纯 $C_{i,j}^{(\ell,r)}$ 更严格，因为只有通讯矩阵有边且 ligand/receptor 表达也支持时，score 才会高。

如果配置 `cross_cell_lr_use_grn_gate` 打开，则代码还会要求 GRN 中存在 ligand 到 receptor 的调控门控，并把 score 改成

$$S_{i,j}^{(\ell,r)} = C_{i,j}^{(\ell,r)} x_{i,\ell} x_{j,r} \tilde{w}_{\ell,r}.$$

这里 $\tilde{w}_{\ell,r}$ 是 ligand gene ℓ 到 receptor gene r 的归一化 GRN 权重。需要强调的是，当前默认可以不打开这个 gate，因为原诊断已经指出 LR-GRN 交集可能过严。不开 gate 时，LR 通道先保留更多 LR 通讯信息；开 gate 时，LR 通道变得更保守、更稀疏。

LR target block 把所有 LR influence 按 receiving unit 的 upper 归属投影：

$$Z_{i,k}^{\text{lr target}} = \sum_{j=1}^n \sum_{(\ell,r)} S_{i,j}^{(\ell,r)} W_{j,k}.$$

这里 $Z_{i,k}^{\text{lr target}}$ 表示第 i 个 unit 通过 ligand-receptor 机制产生的影响中，有多少最终指向第 k 个 stable upper unit； $S_{i,j}^{(\ell,r)}$ 是某个 ligand-receptor pair 对 $i \rightarrow j$ 的影响分数； $W_{j,k}$ 表示被影响的 unit j 属于 upper unit u_k 的程度。

4.8 新版 cross-cell 的完整特征形式

对每一个 unit i ，新版 cross-cell 的完整特征向量为

$$\mathbf{z}_i^{\text{cross}} = \left[Z_{i,1:K}^{\text{grn target}}, Z_{i,1:K}^{\text{cci out target}}, Z_{i,1:K}^{\text{cci in source}}, Z_{i,1:K}^{\text{lr target}} \right].$$

这里 $\mathbf{z}_i^{\text{cross}}$ 是第 i 个 unit 的新版 cross-cell feature vector； $Z_{i,1:K}^{\text{grn target}}$ 是内部 GRN 活性在所有 stable upper units 上的坐标； $Z_{i,1:K}^{\text{cci out target}}$ 是发送通讯的目标 upper 坐标； $Z_{i,1:K}^{\text{cci in source}}$ 是接收通讯的来源 upper 坐标； $Z_{i,1:K}^{\text{lr target}}$ 是 ligand-receptor 影响的目标 upper 坐标。

如果配置 `feature_loglp` 打开，代码会对最终矩阵做

$$\mathbf{z}_i^{\text{cross}} \leftarrow \log(1 + \mathbf{z}_i^{\text{cross}}).$$

这里 $\log(1+x)$ 用来压缩极端大值，避免少数强 CCI 或强 LR 边支配后续 Pij 方法。经过这一步后，Joint NMF、Laplacian、OT、SLAT 等 Pij 方法都会把 $\mathbf{z}_i^{\text{cross}}$ 当作 unit 的网络状态输入。

新版 cross-cell 的一句话总结

旧版 cross-cell 的特征是“这个 unit 总体发送多少、接收多少、熵多大、DDI 多强”；新版 cross-cell 的特征是“这个 unit 的 GRN 活性、CCI 发送、CCI 接收来源、LR 影响分别落到哪些 stable upper units 上”。因此新版 cross-cell 已经从 block-summary representation 改成了 target-aware multichannel upper-coordinate representation。

5 DDI 在新版 cross-cell 中的处理

旧版 cross-cell 中存在 macro DDI block：把 lower-level CCI 通过 overlap 粗粒化到 upper-level DDI，然后再提取 out strength、in strength 和 total strength。新版 cross-cell 的代码中，

DDI 被明确标记为 disabled in target-aware mode。这个修改非常关键，因为它解决了原诊断中的“重复建模”问题。

如果某个层级本身已经生成了 CCI，那么这个层级的 CCI 就应该直接解释为当前 unit 之间的 communication。例如，k150 layer 的 CCI 本身就是 k150 domains 之间的 communication；k40 layer 的 CCI 本身就是 k40 domains 之间的 communication。没有必要在网络模块中再从 lower CCI 粗粒化出一份额外 DDI。新版 cross-cell 的做法是：

当前 layer 的 unit-to-unit CCI $\rightarrow$ target-aware projection $\rightarrow$ upper-coordinate features.

这意味着，新版 cross-cell 不再问“是否额外构造 domain-domain interaction”，而是问“当前层级已有的 communication 指向哪些 stable upper units”。这样既避免重复建模，也减少了由人工 DDI 构造带来的额外风险。

6 新版 Cross-cell 与 Legacy 的关系

Legacy mixed GRN-CCI 和新版 cross-cell 都使用 upper-coordinate 思想，但二者仍然不是同一个网络。

比较点	Legacy mixed GRN-CCI	新版 Cross-cell Multilayer
核心坐标	stable upper units	stable upper units
核心通道	intra influence 与 inter influence 两个 block	GRN target、CCI out target、CCI in source、LR target 四个 block
GRN 角色	GRN 主要参与 intra influence，并参与跨 unit influence 的调控支持	GRN 形成 self activity；LR 通道可选是否使用 GRN gate
CCI 角色	CCI 与 GRN 交集形成 inter influence，再投影到 upper target	CCI total 直接形成 out-target 和 in-source 两个方向通道
LR 角色	更偏向通过 LR-GRN matching 形成跨细胞 influence	单独保留 LR target block，选择不强制 LR-GRN gate
DDI 处理	不额外强调 DDI block	DDI 在 target-aware mode 中禁用，不再重复粗粒化
特征维度	通常是 2K	固定为 4K
回答的问题	lower unit 的内部/跨 unit influence 指向哪个 upper region	lower unit 的调控、发送、接收来源和 LR 影响分别指向哪个 upper region

因此，新版 cross-cell 不是回到旧版 Legacy，也不是继续旧的十四维统计量，而是介于两者之间：它继承 Legacy 的 upper-coordinate 对齐思想，同时保留 cross-cell 原本想表达的多通道生物信息。它比 Legacy 更分块、更能区分“发送方向”和“接收来源”；它比旧版 cross-cell 更适合 vertical EI，因为每一维都绑定到具体 stable upper unit。

7 它对 EI 的帮助：为什么 upper-coordinate 会影响 P_{ij}

EI 衡量的是：知道 source identity 后，target distribution 是否变得更确定。给定 transition matrix P ，effective information 可以写作

$$EI(P) = H\left(\frac{1}{n} \sum_{i=1}^n P_{i\cdot}\right) - \frac{1}{n} \sum_{i=1}^n H(P_{i\cdot}).$$

这里 $P_{i\cdot}$ 是第 i 个 source unit 的整行 target distribution； $H(P_{i\cdot})$ 是给定 source unit i 后 target distribution 的熵；第一项 $H\left(\frac{1}{n} \sum_i P_{i\cdot}\right)$ 是所有 source 混合后的平均 target 熵；第二项 $\frac{1}{n} \sum_i H(P_{i\cdot})$ 是 source 条件下 target 熵的平均值。二者差值越大，说明 source identity 对 target choice 提供的信息越多。

如果网络特征只保存总活跃度，那么许多 units 会被表示成类似的“强发送/强接收/高活跃”模式。OT 或相似度方法得到的 P_{ij} 行分布就容易相似， $H(P_{i\cdot})$ 也不容易下降。相反，如果网络特征保存 target-aware upper-coordinate 信息，那么不同 source units 更容易对应不同 target regions， $P_{i\cdot}$ 的行分布更容易分开，EI 才更可能升高。

需要强调的是，upper-coordinate projection 并没有修改 EI 公式。它改变的是进入 P_{ij} 方法的 feature space。feature space 更能保留“作用指向谁”，后续 cost matrix C_{ij} 、transport plan T_{ij} 和 transition matrix P_{ij} 才更可能形成清晰的跨时间结构。

8 同一个层级在不同 vertical pair 中 EI 不同的原因

同一个 k150 层级，在不同 vertical pair 中扮演的角色不同。在

$$\text{less-than5} \rightarrow \text{k150}$$

这个 pair 中，k150 是 upper layer，k150 units 是 lower features 要投影到的坐标系；而在

$$\text{k150} \rightarrow \text{k40}$$

这个 pair 中，k150 是 lower layer，k150 units 自己又要被写到 k40 stable upper units 的坐标系里。

因此，同一个 k150 的 EI 不是绝对属性，而是与 pair 有关的相对属性。当前 lower 是谁、upper 是谁、stable upper units 如何定义、overlap matrix W 如何构造、cross-cell feature 被写到哪个 upper 坐标系，都会改变 $\mathbf{z}_i^t$ ，进而改变 C_{ij} 、 T_{ij} 和 P_{ij} 。所以 k150 在 less-than5-to-k150 和 k150-to-k40 中出现不同 EI，是合理现象，而不是必然的 bug。

9 基于 result6.18 的 Legacy 网络 EI 结果更新

结果读取原则

本节只读取 result6.18.zip 中 network=legacy_mixed_grn_cci 路径下每个方法目录外围的 metrics.csv 文件，不读取 features/ 目录中的逐 pair 中间文件，也不展示 cross-cell 网络结果表。也就是说，本节回答的是：在新版结果中，只看 Legacy mixed GRN-CCI 网络时，EI_gain 在聚类方式、Pij 方法、层级方向和时间跨度上如何变化。

整体上，本次 Python 汇总共读取 Legacy 网络下 30 个外围 metrics.csv 文件，合并后共有 2130 行实际指标记录。所有表格中的平均值、中位数和正值比例都直接由 EI_gain 列计算得到；其中“正值比例”表示 EI_gain 大于 0 的组合占比。整体 Legacy 网络的平均 EI_gain 为 0.278，中位 EI_gain 为 0.111，EI_gain 大于 0 的比例为 90.7%。

9.1 Legacy 网络下三类聚类方式的 EI_gain

聚类方式	平均 EI_{gain}	中位 EI_{gain}	$EI_{gain} > 0$ 比例
Seurat	0.310	0.128	92.0%
Louvain	0.272	0.112	92.7%
Spatial domain	0.234	0.072	85.7%

从聚类方式看，Seurat 的平均 EI_gain 最高，Louvain 略低，Spatial domain 在本批结果中平均值最低。这个结果不应该被理解为 Spatial domain 一定无效，而应理解为：在当前 Legacy 网络和本批 Pij 方法组合下，聚类方式造成的差异仍然小于 Pij 方法和层级方向造成的差异。换句话说，聚类方式会改变空间 unit 的边界，但 EI_gain 的主要强弱仍然取决于跨时间匹配方式和 lower-to-upper 的层级跨度。

9.2 Legacy 网络下不同 Pij 方法的 EI_gain

Pij 方法	平均 EI_{gain}	中位 EI_{gain}	$EI_{gain} > 0$ 比例
SLAT	0.441	0.247	91.7%
Energy-entropy OT	0.380	0.224	95.8%
Velocity OT	0.374	0.225	88.0%
SR OT	0.368	0.239	92.1%
Pseudotime OT	0.365	0.229	92.1%
Expr OT	0.290	0.110	93.5%
Development OT	0.248	0.128	88.0%
3dOT	0.211	0.072	80.6%
Joint NMF	0.066	0.065	94.4%
Laplacian	0.002	0.003	90.3%

从 Pij 方法看, SLAT 仍然是平均 EI_gain 最高的方法。Energy-entropy OT 排在第二, 说明把网络特征代价、空间代价和 graph energy 代价组合起来之后, 确实能形成较强的跨时间转移结构。新增的 Velocity OT、SR OT 和 Pseudotime OT 都进入较高区间, 它们的平均 EI_gain 接近 Energy-entropy OT, 并且明显高于 Expr OT。这说明发育特征并不是只提供解释性标签, 而是可以实质改变 OT 的 cost matrix C_{ij} , 进而改变 transport plan T_{ij} 和最终进入 EI 的 transition matrix P_{ij} 。

Development OT 的平均 EI_gain 低于单独的 Velocity/SR/Pseudotime OT, 但仍为正。这可能说明综合代价同时加入太多约束后, 匹配会更保守; 也可能说明当前各 component 的权重还没有调到最优。Laplacian 的平均增益仍接近 0, 说明它虽然多数情况下是正值, 但强度很弱, 不适合作为主力 Pij 方法。

9.3 Legacy 网络下不同层级方向的 EI_gain

层级方向	平均 EI_{gain}	中位 EI_{gain}	$EI_{gain} > 0$ 比例
k150 → k40	0.603	0.450	97.1%
less-than5 → k150	0.324	0.106	87.9%
spot → k40	0.231	0.146	97.2%
spot → k150	0.217	0.138	91.3%
less-than5 → k40	0.165	0.080	89.0%
spot → less-than5	0.018	0.002	80.6%

层级方向上, k150 → k40 仍然最强, 平均 EI_gain 达到 0.603。这与 6.15 的结论一致: 有效信息增益最明显的地方不是 spot 到极细 domain 的局部平滑, 而是中等空间模块进一步压缩到更粗宏观区域的过程。spot → less-than5 的平均 EI_gain 仍然最低, 说明从原始 spot 到极小 domain 的变化更接近局部聚合, 不一定产生强的宏观选择性。

9.4 Legacy 网络下不同时间跨度的 EI_gain

时间跨度	平均 EI_{gain}	中位 EI_{gain}	$EI_{gain} > 0$ 比例
11.5 → 12.5	0.246	0.097	92.1%
11.5 → 13.5	0.305	0.134	94.4%
11.5 → 14.5	0.234	0.091	89.0%
12.5 → 13.5	0.317	0.113	88.5%
12.5 → 14.5	0.269	0.102	88.5%
13.5 → 14.5	0.300	0.142	91.5%

从时间跨度看, 12.5 → 13.5 的平均 EI_gain 最高, 13.5 → 14.5 和 11.5 → 13.5 也处在较高区间。所有时间跨度的 EI_gain 正值比例都接近或高于 88%, 说明在 Legacy 网络下, upper layer 在多数跨时间组合中仍然比 lower layer 形成更清晰的条件转移结构。换句话说, 本批 result6.18 支持“宏观空间层级在发育过程中能形成更高 effective information”的总体结论。

本节更新后的重点结论

如果只看 Legacy 网络，6.18 新结果最重要的变化是：新增的发育约束 OT 方法已经进入有效比较范围。Velocity OT、SR OT 和 Pseudotime OT 的平均 EI_gain 都接近 Energy-entropy OT，说明“发育方向、分化潜能、伪时进度”这些外部发育特征对跨时间转移矩阵有真实影响。后续如果要继续扩展 Pij 方法，优先方向应该不是再增加单纯相似度方法，而是进一步校准这些发育约束的权重、缺失值处理和 domain-level 聚合方式。

10 最终落地结论

经过 result6.18 重新汇总后，Legacy 网络的 EI 结果仍然支持 6.15 的主线结论：upper-coordinate 类型的网络表示更容易在宏观层级形成清晰的跨时间转移。新增的发育约束 OT 方法进一步说明，Pij 方法不只是技术性匹配模块，而是直接决定 C_{ij} 、 T_{ij} 和 P_{ij} 的发育假设入口。

对当前报告和代码的结论

当前 6.18 报告应把 cross-cell 网络描述从旧版“固定十四维 feature blocks”更新为新版“target-aware multichannel upper-coordinate features”。新版网络的核心公式是：GRN target block 为 $Z_{i,k}^{\text{grn_target}} = R_i W_{i,k}$ ，CCI out target block 为 $Z_{i,k}^{\text{cci_out_target}} = \sum_j C_{i,j} W_{j,k}$ ，CCI in source block 为 $Z_{i,k}^{\text{cci_in_source}} = \sum_j C_{j,i} W_{j,k}$ ，LR target block 为 $Z_{i,k}^{\text{lr_target}} = \sum_{j,(\ell,r)} S_{i,j}^{(\ell,r)} W_{j,k}$ 。这四个通道共同构成 $4K$ 维特征，并且 DDI 已经不再单独重复建模。

对后续实验解释的结论

OT 方法部分需要明确区分 cost、transport plan 和 transition probability。 C_{ij} 是 source-target 匹配代价， T_{ij} 是全局 OT 约束下的运输质量， P_{ij} 是行归一化后进入 EI/DI/TE-like 的条件概率。Expr OT、Energy-entropy OT、Pseudotime OT、SR OT、Velocity OT 和 Development OT 的区别，主要是 cost components 和 weights 不同，而它们共享同一个 entropic OT 到 row-stochastic transition kernel 的底层。