

研究日志

GRN-CCI 混合网络与新型层级表示的整理修正版

日期：2026 年 6 月 24 日 版本：手写稿修正版

本次整理原则

本稿不是逐字转写版，而是在原手写稿的基础上做了最小必要修正：统一符号、补齐维度、拆开 legacy 混合网络与新网络方案，并把几个容易混淆的地方改成更容易继续写代码和写论文的形式。

1 当前 legacy 网络：每个样本一张 mixed GRN-CCI 表示

1.1 样本、表达矩阵与 GRN

一个样本记为

$$s = (o, t, \ell), \quad (1)$$

其中 o 表示器官， t 表示时间点， ℓ 表示层级。设该样本中有 n_s 个 unit，有 g 个 gene，则输入表达矩阵为

$$X_s \in \mathbb{R}^{n_s \times g}. \quad (2)$$

这里 n_s 是 unit 数， g 是 gene 数。

当前 legacy 构建方式中，每个样本 s 对应一张 GRN：

$$W_s^{\text{GRN}} \in \mathbb{R}^{g \times g}. \quad (3)$$

其中

$$W_s^{\text{GRN}}[i, j] \quad (4)$$

表示 gene i 到 gene j 的调控强度。

1.2 LR pair 与 CCI 矩阵

对于每一个 ligand-receptor pair，记为

$$r = (L, R), \quad (5)$$

其中 L 是 ligand gene， R 是 receptor gene。每一个 LR pair 都对应一张 CCI 矩阵：

$$C_s^{(L, R)} \in \mathbb{R}^{n_s \times n_s}. \quad (6)$$

其中

$$C_s^{(L, R)}[a, b] \quad (7)$$

表示 unit a 到 unit b 之间，沿着 LR pair (L, R) 的细胞通讯强度。

1.3 legacy 中 intra 与 inter 的含义

legacy 网络中可以把信息拆成两类:

$$S_s^{\text{intra}}(i, j) = W_s^{\text{GRN}}[i, j], \quad i, j \text{ 为 gene}, \quad (8)$$

$$S_s^{\text{inter}}(a, b; L, R) = C_s^{(L, R)}[a, b] \cdot W_s^{\text{GRN}}[L, R], \quad a, b \text{ 为 unit}. \quad (9)$$

这里需要注意: S_s^{inter} 不是纯 CCI, 也不是纯 GRN。它把两部分相乘:

$$\text{inter 信息} = \text{CCI 强度} \times \text{GRN 中 } L \rightarrow R \text{ 的调控强度}. \quad (10)$$

修正后的判断

所以当前 legacy 网络的本质是 mixed GRN-CCI representation。它的优点是把细胞通讯和基因调控放在同一个表示里; 但如果目标是做 GRN-only 的 gene-level 粗粒化, 或者想单独消融 CCI/GRN, 就不能直接把这个 S_s^{inter} 当成纯 GRN 或纯 CCI。

2 新网络想解决的问题: lower 与 upper 需要可比较

2.1 一个最小例子

设 lower 层级是 spot:

$$\mathcal{U}^{\text{lower}} = \{s_1, s_2, s_3, s_4, s_5, s_6\}. \quad (11)$$

设 upper 层级是 domain:

$$\mathcal{U}^{\text{upper}} = \{A, B, C\}, \quad (12)$$

其中

$$A = \{s_1, s_2\}, \quad B = \{s_3, s_4, s_5\}, \quad C = \{s_6\}. \quad (13)$$

记 upper unit 的个数为

$$m = |\mathcal{U}^{\text{upper}}|. \quad (14)$$

在这个例子里, $m = 3$ 。

2.2 domain-oriented feature: 把 lower unit 映射到同一套 domain 坐标

为了让 lower 和 upper 可以比较, 一个直接的做法是: 不要只给每个 lower unit 一个孤立特征, 而是让它对每个 upper domain 都有一组关系特征。

对 lower unit u , 构造

$$B_t(u) = [\text{intra-to-}A, \text{intra-to-}B, \text{intra-to-}C, \text{inter-to-}A, \text{inter-to-}B, \text{inter-to-}C]. \quad (15)$$

一般地, 如果 upper domain 为 $d_1, \dots, d_m$, 则

$$B_t(u) = [\phi_t^{\text{intra}}(u, d_1), \dots, \phi_t^{\text{intra}}(u, d_m), \phi_t^{\text{inter}}(u, d_1), \dots, \phi_t^{\text{inter}}(u, d_m)] \in \mathbb{R}^{2m}. \quad (16)$$

其中可以定义为

$$\phi_t^{\text{intra}}(u, d) = \text{Agg}_{v \in d} I_t(u, v), \quad (17)$$

$$\phi_t^{\text{inter}}(u, d) = \text{Agg}_{v \in d} C_t(u, v). \quad (18)$$

这里 $I_t(u, v)$ 表示由 GRN 或 unit 内部 gene activity 汇总出来的 intra 信息, $C_t(u, v)$ 表示 CCI 或 unit-unit communication 信息。Agg 可以是 mean、sum 或归一化后的加权和。

2.3 upper feature: 由 lower feature 聚合得到

对于 upper domain d , 可以用其包含的 lower unit 来平均:

$$B_t^{\text{upper}}(d) = \frac{1}{|d|} \sum_{u \in d} B_t^{\text{lower}}(u). \quad (19)$$

这样 lower 与 upper 都在同一个坐标系里:

$$B_t^{\text{lower}} \in \mathbb{R}^{n \times 2m}, \quad B_t^{\text{upper}} \in \mathbb{R}^{m \times 2m}. \quad (20)$$

最后可以拼接为

$$Z_t = \begin{bmatrix} B_t^{\text{lower}} \\ B_t^{\text{upper}} \end{bmatrix} \in \mathbb{R}^{(n+m) \times 2m}. \quad (21)$$

如果维度太高, 或者不同样本之间的 domain 数不一致, 可以再用 PCA 或统一字典做降维与对齐。

修正后的理解

这一步的关键不是简单地“把 gene network 变成 domain 信息”, 而是把 lower unit 与 upper unit 都放进同一套 domain-oriented 坐标中。这样后面算 PIJ、EI 或跨层级比较时, lower/upper 的表示空间才是可比的。

3 gene-based 新网络: 避免再把 GRN 与 CCI 混在一起

3.1 为什么需要 gene-based 版本

如果当前目标是 gene-level GRN coarse-graining, 那么核心对象应当是 gene expression 与 GRN 派生出的 gene activity, 而不是把 CCI 再混进去。否则得到的仍然是 mixed representation, 不能回答“只基于 GRN 的粗粒化是否有效”这个问题。

3.2 lower 与 upper 的 gene-based 表示

设 lower 层级有 n 个 unit, gene 数为 g 。lower 层级表达矩阵为

$$E_t^{\text{lower}} \in \mathbb{R}^{n \times g}. \quad (22)$$

upper 层级有 m 个 unit。若 upper unit d 由 lower unit 集合组成, 则

$$E_t^{\text{upper}}(d, :) = \frac{1}{|d|} \sum_{u \in d} E_t^{\text{lower}}(u, :). \quad (23)$$

因此

$$E_t^{\text{upper}} \in \mathbb{R}^{m \times g}. \quad (24)$$

如果需要引入 GRN，可以用同一张或同一规则生成的 GRN 矩阵 $W_t^{\text{GRN}} \in \mathbb{R}^{g \times g}$ 得到 gene activity:

$$G_t^{\text{lower}} = E_t^{\text{lower}} W_t^{\text{GRN}} \in \mathbb{R}^{n \times g}, \quad (25)$$

$$G_t^{\text{upper}} = E_t^{\text{upper}} W_t^{\text{GRN}} \in \mathbb{R}^{m \times g}. \quad (26)$$

于是可以构造

$$R_t^{\text{lower}} = [E_t^{\text{lower}}, G_t^{\text{lower}}] \in \mathbb{R}^{n \times 2g}, \quad (27)$$

$$R_t^{\text{upper}} = [E_t^{\text{upper}}, G_t^{\text{upper}}] \in \mathbb{R}^{m \times 2g}. \quad (28)$$

最终拼接:

$$R_t = \begin{bmatrix} R_t^{\text{lower}} \\ R_t^{\text{upper}} \end{bmatrix} \in \mathbb{R}^{(n+m) \times 2g}. \quad (29)$$

3.3 三个可分开的版本

为了后续消融，建议把下面三种表示分开:

版本	含义
pure expression	只使用 E_t ，不使用 GRN，也不使用 CCI。
GRN-only gene-based	使用 E_t 与 $G_t = E_t W_t^{\text{GRN}}$ ，不使用 CCI。
mixed GRN-CCI legacy	使用 W_t^{GRN} 与 $C_t^{(L,R)}$ ，并在 inter 项中相乘。

修正后的判断

原手写稿里 “ $F_t \rightarrow \mathbb{R}^{m \times g}$ 为什么可以平均” 这个地方可以这样理解：平均的对象不是 GRN 本身，而是 lower unit 的 gene expression 或 gene activity。只要 upper unit 是由 lower unit 聚合来的， E_t^{upper} 和 G_t^{upper} 就可以通过成员 lower unit 的均值或加权均值得到。

4 目前可以写进代码或论文里的结论

1. 当前 legacy 网络中， $S_s^{\text{inter}}(a, b; L, R) = C_s^{(L,R)}[a, b] \cdot W_s^{\text{GRN}}[L, R]$ ，因此它是混合了 CCI 与 GRN 的网络表示。
2. 如果要做 CCI-only 或 GRN-only 消融，就必须把 $C_s^{(L,R)}$ 与 W_s^{GRN} 拆开，不能继续沿用 legacy 的 inter 相乘项。
3. 如果要做 gene-level GRN coarse-graining，更干净的方式是构建 gene-based 表示：先保留 $E_t \in \mathbb{R}^{n \times g}$ ，再用 W_t^{GRN} 生成 $G_t = E_t W_t^{\text{GRN}}$ 。

4. lower 与 upper 的可比性来自共同的坐标空间：要么共同使用 gene 坐标 g ，要么共同使用 domain-oriented 坐标 $2m$ 。
5. 新网络是否“像网络”不是最重要的问题。更重要的是：它能否形成可比较的 lower/upper 表示，并在此基础上稳定地产生 PIJ 与 EI。

5 下一步开发建议

1. 在代码中明确保留 legacy mixed GRN-CCI 网络，不要直接覆盖。
2. 新增 gene-based GRN-only 网络构建入口，输出 lower/upper 的 E_t 、 G_t 或 $[E_t, G_t]$ 。
3. 新增 CCI-only 版本，使 inter 信息只来自 $C_s^{(L,R)}$ ，不再乘 $W_s^{\text{GRN}}[L, R]$ 。
4. 后续跑 vertical ablation 时，把 network method 显式写成：legacy_mixed_grn_cci、grn_only_gene_based、cci_only。

6 Seurat 与 Louvain 结果文件检查与 PIJ 效果汇总

6.1 读取口径

本节使用 Python 直接读取 `mignet_vertical_ablation_seurat_louvain.zip` 中的所有 `metrics.csv`、`run_summary.csv` 与 `run_config.json`。本次共检查 **38** 个 PIJ 结果文件夹；文件层面上，所有文件夹均包含 `metrics.csv`、`run_summary.csv` 与 `run_config.json`。

需要区分两种“齐”：第一，文件是否齐，即每个 PIJ 文件夹内是否都有三类结果文件；第二，实验覆盖是否齐，即每个 organ、layer pair 是否都成功写入 `metrics`。当前文件层面是齐的，但实验覆盖层面仍有缺口：Seurat 的 legacy 与两个修正网络中，brain 只写入了 `k150 -> k40`，缺少 `spot -> k150` 与 `spot -> k40`；Louvain 中 brain 三个 layer pair 均缺失。因此后续表格均按已经成功写入的 `metrics.csv` 行进行统计。

统计指标以 $EI_{gain} = EI_{upper} - EI_{lower}$ 为主。表中 Mean 表示平均 EI_{gain} ，Median 表示中位数 EI_{gain} ，Pos. 表示 $EI_{gain} > 0$ 的比例。当前所有记录中，截断后的 DI 与 TE 均为 0，因此本节不把 DI/TE 作为排序指标。

聚类	网络	PIJ 夹	文件齐	written/PIJ	error/PIJ	metrics 覆盖
louvain	legacy mixed GRN-CCI	6	是	6	3	36 rows; heart, lung
louvain	expression only	1	是	6	3	36 rows; heart, lung
louvain	legacy inter-additive GRN-CCI	6	是	6	3	36 rows; heart, lung
louvain	legacy inter CCI-only	6	是	6	3	36 rows; heart, lung
seurat	legacy mixed GRN-CCI	6	是	7	2	42 rows; brain, heart, lung
seurat	expression only	1	是	9	0	54 rows; brain, heart, lung
seurat	legacy inter-additive GRN-CCI	6	是	7	2	42 rows; brain, heart, lung
seurat	legacy inter CCI-only	6	是	7	2	42 rows; brain, heart, lung

表 1: 结果文件完整性检查。文件齐表示每个 PIJ 文件夹均包含 `metrics.csv`、`run_summary.csv` 与 `run_config.json`。

6.2 legacy mixed GRN-CCI 网络：加入 pure expression OT 对照

这一张表只看 `legacy_mixed_grn_cci` 网络。为了方便对照，把 `expression_only` 网络下的 `pure_expression_ot` 也放进同一张表，并用加粗与底色标出。需要注意，`pure expression OT` 的样本覆盖与 `legacy` 网络不完全一致，所以它主要作为表达信息单独使用时的参考线，而不是严格同样本量下的横向比较。

PIJ 方法	<i>n</i>	Mean	Median	Pos.	Seurat	Louvain
SLAT	78	0.658	0.396	94.9%	0.735	0.568
Expr + Pseudotime + SR + Energy OT	78	0.639	0.457	93.6%	0.683	0.588
Expr + Pseudotime + SR + Energy + Spatial OT	78	0.623	0.443	93.6%	0.664	0.576
Pseudotime + Expression OT	78	0.597	0.395	96.2%	0.637	0.551
Expr + Pseudotime + SR OT	78	0.594	0.407	96.2%	0.632	0.549
Expr + Pseudotime + SR + Spatial OT	78	0.585	0.400	96.2%	0.620	0.545
Pure Expression OT (expression only)	90	0.140	0.133	74.4%	0.105	0.192

表 2: legacy mixed GRN-CCI 网络下各 PIJ 方法的 EI_gain 汇总; pure expression OT 为额外加入的 expression-only 对照。

从当前结果看, legacy mixed 网络内平均 EI_{gain} 最高的是 SLAT, 其次是 Expr + Pseudotime + SR + Energy OT。Pure Expression OT 的平均 EI_{gain} 明显低于 legacy mixed 网络下的 PIJ 方法, 但它的覆盖范围更宽, 因此目前只作为表达-only 基线参考。

6.3 legacy inter-additive GRN-CCI 修正网络

这一张表只看 legacy_inter_additive_grn_cci。这里不放 pure expression OT, 因为该表的目标是比较修正后的 inter-additive 网络内部, 不混入 expression-only 网络。

PIJ 方法	<i>n</i>	Mean	Median	Pos.	Seurat	Louvain
SLAT	78	0.658	0.396	94.9%	0.735	0.567
Expr + Pseudotime + SR + Energy OT	78	0.639	0.457	93.6%	0.683	0.588
Expr + Pseudotime + SR + Energy + Spatial OT	78	0.623	0.443	93.6%	0.664	0.576
Pseudotime + Expression OT	78	0.597	0.395	96.2%	0.637	0.551
Expr + Pseudotime + SR OT	78	0.594	0.407	96.2%	0.632	0.549
Expr + Pseudotime + SR + Spatial OT	78	0.585	0.400	96.2%	0.620	0.545

表 3: legacy inter-additive GRN-CCI 网络下各 PIJ 方法的 EI_gain 汇总。

6.4 legacy inter CCI-only 修正网络

这一张表只看 legacy_inter_cci_only。这里同样不放 pure expression OT。

PIJ 方法	<i>n</i>	Mean	Median	Pos.	Seurat	Louvain
SLAT	78	0.666	0.396	94.9%	0.750	0.568
Expr + Pseudotime + SR + Energy OT	78	0.665	0.505	93.6%	0.732	0.588
Expr + Pseudotime + SR + Energy + Spatial OT	78	0.651	0.499	93.6%	0.715	0.576
Pseudotime + Expression OT	78	0.619	0.440	96.2%	0.678	0.551
Expr + Pseudotime + SR OT	78	0.617	0.451	96.2%	0.674	0.549
Expr + Pseudotime + SR + Spatial OT	78	0.609	0.439	96.2%	0.664	0.545

表 4: legacy inter CCI-only 网络下各 PIJ 方法的 EI_gain 汇总。

6.5 按 PIJ 方法汇总全部非 expression-only 数据

这一张表把 Seurat 与 Louvain、三个非 expression-only 网络全部合并，每一行对应一个 PIJ 方法。这里刻意不纳入 pure_expression_ot，因为 pure expression OT 只在 expression_only 网络上运行，样本量和网络对象都不一样。

PIJ 方法	<i>n</i>	Mean	Median	Pos.	Mixed	Additive	CCI-only
SLAT	234	0.660	0.396	94.9%	0.658	0.658	0.666
Expr + Pseudotime + SR + Energy OT	234	0.648	0.466	93.6%	0.639	0.639	0.665
Expr + Pseudotime + SR + Energy + Spatial OT	234	0.633	0.482	93.6%	0.623	0.623	0.651
Pseudotime + Expression OT	234	0.605	0.411	96.2%	0.597	0.597	0.619
Expr + Pseudotime + SR OT	234	0.602	0.414	96.2%	0.594	0.594	0.617
Expr + Pseudotime + SR + Spatial OT	234	0.593	0.422	96.2%	0.585	0.585	0.609

表 5: 按 PIJ 方法汇总全部非 expression-only 数据。这里不纳入 pure expression OT，因为它只在 expression-only 网络上运行，样本覆盖与其它 PIJ 方法不一致。

整体看，当前非 expression-only 数据中，SLAT 的平均 EI_{gain} 最高；Expr + Pseudotime + SR + Energy OT 排在第二；加入 Spatial 后，当前汇总均值没有继续上升。三个网络之间，legacy_inter_cci_only 的整体均值略高，但差异主要体现在 Seurat 部分，Louvain 部分不同网络之间非常接近。

本次结果的暂时判断

当前结果文件可以用于做阶段性汇总，但不能说所有 organ 与 layer pair 已经完全跑齐。后续如果要做最终论文表，至少需要补齐 Louvain brain，以及 Seurat 下 legacy/修正网络的 brain spot-to-domain 两类 pair；否则 pure expression OT 与其它网络方法之间的比较会受到样本覆盖差异影响。