

MIGNet 无泄露特征重构 Codex Plan

GRN 做 intra, CCI 做 inter, native units 直接计算 P_{ij}

面向代码修改与方法讨论的中文计划：保留现有 DataFactory 结果，不再使用 GRN 处理 inter，不再把 lower 特征投影到 upper 坐标。

本轮方案一句话

对每个器官、时间点和 layer，保留当前样本自己的 unit。unit 内部信息只来自 GRN 的 gene-to-gene 边权；unit 之间信息只来自 CCI/LR 通信分数。lower layer 和 upper layer 分别在自己的 native unit 空间中构造跨时间 P_{ij} ，最后用 $EI_{gain} = EI(P_{upper}) - EI(P_{lower})$ 比较宏观层级和微观层级的信息组织差异。

目录

1 本轮决策：只保留 CCI inter	2
2 为什么暂时不用 GRN 做 inter	2
3 新的 unit 表征	3
3.1 Intra: GRN 内部边权	3
3.2 Inter: CCI/LR 通信边权	3
4 native feature matrix 如何接回 P_{ij}	3
4.1 OT 的 cost 仍然可以沿用	4
4.2 lower 和 upper 分开计算	4
5 和现有代码体系的对接	4
5.1 新增 native 特征构建模块	5
5.2 新增网络结构	5
5.3 representation 层需要加 native 分支	5
5.4 发育特征加载需要改	5
5.5 metrics 需要保护	5
5.6 P_{ij} 导出需要改	6
6 Codex 实施顺序	6
7 建议第一轮实验	6
8 SLAT 的 P_{ij} 到 EI 链路	7
9 最终验收标准	7

1 本轮决策：只保留 CCI inter

保留和删除的内容		
内容	本轮处理	原因
GRN 处理 unit 之间 inter	不做	当前 GRN 是 gene-to-gene, 没有 cell 或 unit 信息；直接构造跨 unit GRN 会引入额外假设。
GRN 与 CCI 相乘	不做	容易变成复合建模，解释不干净。
GRN 与 CCI 相加	不做	本轮不需要 additive 版本，避免重复建模。
GRN 边权再乘表达量	不做	GRN 已由表达推断，表达量最多作为可选 mask，不进入边权强度。
lower 特征投影到 upper 坐标	不做	这是当前信息泄露的主要来源。
发育特征的 lower-to-upper 聚合	不做	pseudotime 和 SR 也必须跟随 native units。

新网络建议命名为：

native GRN-intra CCI-inter network

它的含义是：

$$\text{unit feature} = [\text{intra from GRN}, \text{inter from CCI}].$$

这里的“native”表示每一行仍然是当前 layer 当前时间点自己的 unit，不做 lower 到 upper 的重写。

2 为什么暂时不用 GRN 做 inter

当前 DataFactory 输出的 GRN 本质是：

$$g \longrightarrow h,$$

也就是基因到基因的调控边。它没有直接告诉我们：

$$(u, g) \longrightarrow (v, h), \quad u \neq v,$$

即 unit u 中的基因 g 是否跨 unit 影响 unit v 中的基因 h 。如果强行把 gene-level GRN 复制到所有 unit pair 上，那么 inter 会接近全连接背景噪声；如果只在部分 unit pair 上复制，就必须额外定义空间邻接、表达邻接或其他跨 unit 条件。本轮不引入这些新假设，因此 inter 直接使用已有的 CCI/LR 通信分数。

这不是放弃 GRN inter

未来如果有真正的 cell-gene 或 unit-gene 大 GRN，或者有明确的跨 unit 邻接假设，可以再开一个 GRN-inter 版本。但当前数据条件下，最稳妥的无泄露版本是：GRN 只管 intra，CCI 只管

inter。

3 新的 unit 表征

设某个时间点某个 layer 的 unit 集合为 U ，基因集合为 G 。概念上可以把大图节点写成：

$$(u, g), \quad u \in U, g \in G.$$

但本轮真正要输出的不是完整大图邻接矩阵，而是每个 unit 的特征向量：

$$z_u = [z_u^{intra}, z_u^{inter}].$$

3.1 Intra: GRN 内部边权

若 GRN 中存在一条边 $g \rightarrow h$ ，其归一化权重为 $w_{g,h}$ 。unit u 在这条边对应维度上的 intra 特征为：

intra 特征

$$z_{u,(g,h)}^{intra} = w_{g,h} \cdot a_{u,g} \cdot a_{u,h}.$$

其中 $a_{u,g}$ 是一个可选激活指示函数，只表示基因 g 在 unit u 中是否可检测。它不把表达量作为连续强度乘进去。

为什么还需要可选 mask

当前 GRN 是 sample-level 的 gene-to-gene 网络。如果完全不用 unit 层面的激活判断，同一个样本里的许多 unit 会拿到非常相似的 intra GRN 特征。mask 的作用只是让同一张 GRN 在不同 unit 中表现出不同的活跃子图；它不是表达量重复乘法。

3.2 Inter: CCI/LR 通信边权

若 CCI 给出 ligand-receptor 对 (ℓ, r) 从 unit u 到 unit v 的通信分数 $c_{u \rightarrow v}^{(\ell, r)}$ ，则 unit u 的 inter 特征为：

inter 特征

$$z_{u,(\ell, r)}^{inter} = \sum_{v \neq u} c_{u \rightarrow v}^{(\ell, r)}.$$

这个 block 不再拆成 sender 和 receiver 两套特征，而是沿用 legacy 的直觉：从当前 unit 出发，它对其他 unit 形成了多少跨 unit 通信。这里不乘 GRN，不加表达量，也不做 additive。

4 native feature matrix 如何接回 P_{ij}

对一个 layer 和时间点 t ，得到矩阵：

$$Z^{t,L} \in \mathbb{R}^{n_t, L \times d}.$$

其中 $n_{t,L}$ 是当前 layer 当前时间点的 unit 数, d 是统一的特征维度。对 lower 和 upper 分别有:

$$Z_{lower}^t \in \mathbb{R}^{n_t \times d}, \quad Z_{lower}^{t'} \in \mathbb{R}^{n_{t'} \times d},$$

$$Z_{upper}^t \in \mathbb{R}^{m_t \times d}, \quad Z_{upper}^{t'} \in \mathbb{R}^{m_{t'} \times d}.$$

不要求 $n_t = m_t$, 也不要求 $n_t = n_{t'}$ 。只要求同一个 vertical pair 中所有矩阵的列含义一致。

4.1 OT 的 cost 仍然可以沿用

表达/网络特征 OT 的 cost 可以直接写成:

feature cost

$$C_{ij} = 1 - \frac{z_i^t \cdot z_j^{t'}}{\|z_i^t\|_2 \|z_j^{t'}\|_2}.$$

这里 i 是 source time 的 unit, j 是 target time 的 unit。只要两个矩阵的列空间一致, 矩阵可以是矩形。

随后通过熵正则最优传输得到转移概率:

$$P^{t \rightarrow t'} \in \mathbb{R}^{n_t \times n_{t'}}.$$

该矩阵每一行归一化, 表示: 给定时间 t 的某个 source unit, 它转移到时间 t' 各 target units 的概率。

4.2 lower 和 upper 分开计算

native 模式下, lower 和 upper 不再共享 stable upper 坐标。跨时间转移应分别计算:

$$P_{lower}^{t \rightarrow t'} = \text{OT}(Z_{lower}^t, Z_{lower}^{t'}),$$

$$P_{upper}^{t \rightarrow t'} = \text{OT}(Z_{upper}^t, Z_{upper}^{t'}).$$

最后仍然计算:

EI gain

$$EI_{gain} = EI(P_{upper}^{t \rightarrow t'}) - EI(P_{lower}^{t \rightarrow t'}).$$

这一步不需要 lower 和 upper 的 unit 数相同, 因此不会迫使我们重新使用 overlap 投影。

5 和现有代码体系的对接

5.1 新增 native 特征构建模块

建议新增模块

新增一个 native feature builder, 负责把每个样本的 intra 边表和 inter 边表变成 native unit feature matrix。它需要完成四件事:

1. 建立统一特征字典: GRN gene-pair 字典和 LR-pair 字典。
2. 按当前 unit 顺序生成矩阵行。
3. intra block 聚合 unit 内部 GRN 边权。
4. inter block 聚合当前 unit 指向其他 units 的 CCI/LR 分数。

5.2 新增网络结构

新增一个网络结构, 逻辑上等价于:

$$\text{intra} = \text{GRN}, \quad \text{inter} = \text{CCI only}, \quad \text{alignment} = \text{native units}.$$

它可以复用现有边构建流程中的 CCI-only 模式, 但不能调用旧的 lower-to-upper 矩阵构建。旧 legacy 方法全部保留, 作为历史结果和泄露对照。

5.3 representation 层需要加 native 分支

当前 graph feature、Joint NMF 和 Laplacian representation 都会把 lower 结果聚合到 upper 坐标。需要加分支:

- 如果是旧网络, 保持原来的 stable-upper 行为;
- 如果是 native 网络, 直接使用 lower 和 upper 自己的矩阵行;
- native 模式下 lower 坐标也必须是 lower units 的坐标, 不能继续复用 upper 坐标。

5.4 发育特征加载需要改

pseudotime 和 SR 进入 OT 时, 也不能把 lower 发育特征聚合到 upper。native 模式下应当:

$$\text{lower developmental feature} \rightarrow \text{lower units},$$

$$\text{upper developmental feature} \rightarrow \text{upper units}.$$

如果只有 spot-level 发育特征, 可以聚合到当前 layer 的 units, 但不能跨 layer 聚合。

5.5 metrics 需要保护

EI 可以直接在矩形 P 上计算。但 TE/DI 的 Kraskov 条件熵需要样本行数可拼接。native 模式下常常有:

$$n_{\text{lower}} \neq n_{\text{upper}}, \quad n_t \neq n_{t'}.$$

因此第一版建议:

- EI 和 EI gain 正常输出；
- TE 和 DI 在不适用时写为空值；
- 输出表中明确记录这是 native-unit EI-only 模式。

5.6 P_{ij} 导出需要改

旧导出默认 lower 和 upper 都是同一组 stable upper units，因此一个 units 文件就够。native 模式下必须为每个 layer 和每个时间点写 unit mapping：

lower_t source units, lower_{t'} target units,

upper_t source units, upper_{t'} target units.

否则矩形矩阵的行列含义会丢失。

6 Codex 实施顺序

阶段	修改目标	验收标准
1	新增 native feature schema 与 matrix builder	能从一组边表得到 unit 行、GRN pair 列和 LR pair 列的矩阵。
2	新增 GRN-intra + CCI-inter 网络结构	输出的 lower/upper 矩阵行数等于当前 layer 当前时间点的 native unit 数。
3	representation 加 native 分支	graph feature、Joint NMF、Laplacian 不再自动做 lower-to-upper 聚合。
4	OT 与 SLAT 接 native features	Expr OT、development-expression OT、SLAT 都能在 native rows 上产生矩形 P_{ij} 。
5	metrics 保护	EI 正常输出；TE/DI 不适用时为空值而不是报错。
6	P_{ij} 导出改造	sparse 矩阵和 source/target unit mapping 同时写出。
7	小样本集成测试	一个器官、两个时间点、一个 layer pair 可跑通并写出 metrics。

7 建议第一轮实验

- 第一轮不要铺太大矩阵，先验证新特征是否能稳定接上 OT 与 EI：
- 网络结构：native GRN-intra CCI-inter。
 - P_{ij} 方法：Expr OT、Pseudotime + Expr OT、SR + Expr OT、Expr + Pseudotime + SR OT。
 - 对照网络：旧的 mixed GRN-CCI 与旧的 CCI-only legacy。
 - 主指标：EI、EI gain。DI/TE 暂时只作为不适用说明，不作为排名依据。

8 SLAT 的 P_{ij} 到 EI 链路

SLAT 在当前代码中的角色

SLAT 不是直接算 EI，也不是直接输出因果指标。它只负责把两个时间点的 units 对齐成一个跨时间转移概率矩阵。EI 是后面的统一 metrics 模块根据这个概率矩阵计算出来的。

当前 SLAT 流程可以抽象为四步：

1. 先拿到两个时间点的 unit feature 和空间坐标；
 2. 在每个时间点内部，根据空间坐标构建 KNN 空间图；
 3. 交给 SLAT 学习两个时间点 units 的图表示；
 4. 用学到的 source embedding 和 target embedding 计算余弦相似度，再做行归一化，得到 P_{ij} 。
- 因此：

$$\text{features} + \text{coordinates} \rightarrow \text{SLAT embeddings} \rightarrow P_{ij} \rightarrow EI(P_{ij}).$$

EI 的计算公式仍然是：

$$EI(P) = H\left(\frac{1}{n} \sum_i P_{i\cdot}\right) - \frac{1}{n} \sum_i H(P_{i\cdot}).$$

如果 SLAT 给出的 P 更集中、更能让不同 source units 指向不同 target units，那么 EI 会更高；如果每一行都差不多，EI 会更低。

9 最终验收标准

完成后应满足

1. 新网络不使用 GRN 处理 inter，只使用 CCI/LR 分数处理 inter。
2. intra 只使用 GRN 内部边权，表达最多作为 mask。
3. 特征构建阶段不再使用 lower-to-upper overlap 投影。
4. native lower 和 native upper 可以有不同 unit 数量。
5. OT、SLAT 等 P_{ij} 方法可以产生矩形转移矩阵。
6. EI gain 可以正常输出。
7. DI/TE 不适用时显式为空值或标注，不偷偷重新对齐。
8. sparse P_{ij} 导出时，矩阵行列的 source/target units 都有明确 mapping。