

轻量级 CCI/DDI 网络 + Laplacian/JointNMF + SR-OT 方案

面向 MIGNet vertical ablation 的第一版实验设计

根据当前代码中 `clean_expression_cci_mix`、`laplacian`、`joint_nmf`、`sr_ot` 的结构整理

1 一句话结论

当前最新的 `clean_grn_cci_expr_mix` / `clean_expression_cci_mix` 之所以重，是因为它会为每个时间点、每个层级构造高维的“表达基因块 + LR/CCI 特征块”。更稳妥的第一版方案是：网络只保留 CCI/DDI 边；特征不再直接拼大表达矩阵；PIJ 用 Laplacian 或 JointNMF 得到低维结构表征，再和 SR 标量成本合成一个 OT 成本矩阵。

建议新增一个轻量网络方法，例如 `clean_cci_ddi_graph`，参照 `clean_expression_cci_mix` 的 `native_units` 逻辑：每层独立建图，不把 lower feature 预先投影到 upper；overlap 只用于层级对应关系和后续指标，不参与网络特征构造。

2 当前代码观察与问题定位

我看到当前代码里已有几个关键事实：

- `clean_expression_cci_mix.py` 读取每个 layer/time 的 h5ad、COMMOT manifest、COMMOT sparse LR 文件，调用 `build_layer_cci_graph` 生成 CCI 图；metadata 中已经标记 `uses_grn=False`。
- 但该 builder 随后仍然构造表达块和全量 native graph matrix，并把二者横向拼接。这一步会形成很大的 node-by-feature 矩阵，是计算量和内存压力的主要来源之一。
- 现有 `laplacian` 方法实际上只需要 `lower_graphs` / `upper_graphs`，不需要那张巨大的表达 + CCI 矩阵。
- 现有 `sr_ot` 是纯 SR 成本；`sr_expression_ot` 是 SR + graph feature 成本，但 graph feature 还是来自当前 `context.lower_mats` 的大矩阵，不是 Laplacian 或 JointNMF 的轻量结构表征。

所以这次不是简单把命令换成 `laplacian joint_nmf sr_ot`，而是要补一个组合型 PIJ：`laplacian_sr_ot` 和 `joint_nmf_sr_ot`。

3 新的多层网络应该长什么样

3.1 层级语义

这版先把旧 GRN 混合逻辑拿掉。网络按层级解释如下：

- **cell/spot 层**：节点是 cell 或 spot，边是 cell-to-cell communication，记作 CCI。

- **domain 层及更高层**：节点是 domain，边是 domain-to-domain interaction，记作 DDI。实现上可以继续复用 COMMOT 的 LR sparse matrix，只是节点单位已经从 cell/spot 变成 domain。
- **gene 层**：如果以后重新引入，只能作为单独的跨细胞 gene regulation 层；第一版先不进入 PIJ 特征，避免又回到 GRN 乘 CCI 的重模型。

3.2 图的定义

对一个器官、一个时间点和一个层级，定义：

- r 表示器官，例如 heart、brain 或 lung。
- t 表示发育时间点，例如 11.5、12.5、13.5、14.5。
- ℓ 表示层级，例如 spot、louvain_less_than5、louvain_k150、louvain_k40。
- $V_{\ell,t}^{(r)}$ 表示在器官 r 、时间点 t 、层级 ℓ 下的节点集合；节点可以是 cell/spot，也可以是 domain。
- $q \in \mathcal{Q}$ 表示一个 ligand-receptor pair， $\mathcal{Q}$ 是 COMMOT manifest 中的 LR pair 集合。
- $M_{\ell,t}^{(q)} \in \mathbb{R}_{\geq 0}^{|V_{\ell,t}^{(r)}| \times |V_{\ell,t}^{(r)}|}$ 表示第 q 个 LR pair 的 COMMOT 稀疏通信矩阵。

对节点 $u, v \in V_{\ell,t}^{(r)}$ ，构造归一化后的 CCI/DDI 权重：


$$\widetilde{M}_{uv}^{(q)} = \text{Norm}_{\ell,t,q} \left(M_{uv}^{(q)} \right) \cdot \mathbf{1} \left[M_{uv}^{(q)} \geq \tau_{\text{cci}} \right] \cdot G_{uv}^{(q)}. \quad (1)$$

这里， $\text{Norm}_{\ell,t,q}(\cdot)$ 表示对同一层级、同一时间点、同一 LR pair 的非零 COMMOT 分数做缩放； τ_{cci} 是 CCI 分数阈值； $\mathbf{1}[\cdot]$ 是指示函数，条件成立取 1，否则取 0； $G_{uv}^{(q)}$ 是表达门控项，第一版可设为 1，或者沿用当前代码的 ligand/receptor 表达 mask，但不引入 GRN 权重。

然后把 LR pair 聚合成节点间邻接权重：

$$A_{\ell,t}^{(r)}(u, v) = \sum_{q \in \mathcal{Q}} \widetilde{M}_{uv}^{(q)}. \quad (2)$$

这里， $A_{\ell,t}^{(r)}$ 是该层的有向加权邻接矩阵。若 ℓ 是 cell/spot 层，这个矩阵解释为 CCI；若 ℓ 是 domain 层，这个矩阵解释为 DDI。



4 Laplacian + SR: 推荐作为最快第一版

4.1 结构表征

Laplacian 方案不需要 node-by-gene 的表达大矩阵，只需要图的邻接矩阵。由于 CCI/DDI 原始边是有向的，而标准谱分解一般要求对称矩阵，先做对称化：

$$S_{\ell,t}^{(r)} = \frac{1}{2} \left(A_{\ell,t}^{(r)} + A_{\ell,t}^{(r)\top} \right). \quad (3)$$

这里, $S_{\ell,t}^{(r)}$ 是对称邻接矩阵, $A_{\ell,t}^{(r)\top}$ 是 $A_{\ell,t}^{(r)}$ 的转置。

定义度矩阵:

$$D_{\ell,t}^{(r)}(i, i) = \sum_j S_{\ell,t}^{(r)}(i, j). \quad (4)$$

这里, $D_{\ell,t}^{(r)}$ 是对角矩阵, i 和 j 都表示当前层级图中的节点索引。

归一化图拉普拉斯为:

$$L_{\ell,t}^{(r)} = I - D_{\ell,t}^{(r)-1/2} S_{\ell,t}^{(r)} D_{\ell,t}^{(r)-1/2}. \quad (5)$$

这里, $L_{\ell,t}^{(r)}$ 是 normalized Laplacian, I 是单位矩阵, $D^{-1/2}$ 表示对角元素开方后取倒数。

对 $L_{\ell,t}^{(r)}$ 做特征分解:

$$L_{\ell,t}^{(r)} \phi_m = \lambda_m \phi_m, \quad m = 1, 2, \dots, K. \quad (6)$$

这里, λ_m 是第 m 个特征值, ϕ_m 是对应的特征向量, K 是保留的谱分量数量。

直接拿不同时间点图的 eigenvector 坐标做跨图比较会有符号翻转和旋转不唯一的问题。更稳的版本是用 heat kernel signature, 既保留 Laplacian 结构信息, 又避免 eigenvector 符号任意性。

对节点 i , 定义 Laplacian-HKS 表征:

$$z_{i,h}^{\text{lap}} = \sum_{m=1}^K \exp(-\tau_h \lambda_m) \phi_m(i)^2, \quad h = 1, 2, \dots, H. \quad (7)$$

这里, $z_{i,h}^{\text{lap}}$ 是节点 i 在第 h 个 diffusion scale 下的结构特征; τ_h 是第 h 个扩散尺度; H 是扩散尺度数量; $\phi_m(i)$ 表示第 m 个特征向量在节点 i 上的值。平方项 $\phi_m(i)^2$ 可以消除特征向量整体正负号不确定的问题。

最终节点结构向量为:

$$z_i^{\text{lap}} = [z_{i,1}^{\text{lap}}, z_{i,2}^{\text{lap}}, \dots, z_{i,H}^{\text{lap}}]. \quad (8)$$

这里, z_i^{lap} 是节点 i 的低维 Laplacian 结构特征。

4.2 与 SR 合成 OT 成本

设 s_i 表示节点 i 的 SR 值。代码层面就是 developmental feature 表中的 sr 列; 如果没有 sr, 可退而使用 potency_score。如果节点是 domain, 而只有 spot 级 SR, 则用同一时间点的 spot-to-domain map 聚合:

$$s_u = \frac{1}{|\mathcal{S}(u)|} \sum_{a \in \mathcal{S}(u)} s_a. \quad (9)$$

这里, u 表示 domain 节点; $\mathcal{S}(u)$ 表示被分到 domain u 的 spot 集合; a 表示一个 spot; $|\mathcal{S}(u)|$ 是集合大小。

对从时间点 t_0 到时间点 t_1 的 PIJ, 令 $i \in V_{\ell,t_0}^{(r)}$ 是 source 节点, $j \in V_{\ell,t_1}^{(r)}$ 是 target 节点。结构成本为:

$$C_{ij}^{\text{struct}} = \text{Normalize}(d(z_i, z_j)). \quad (10)$$

这里, C_{ij}^{struct} 是结构差异成本; $d(\cdot, \cdot)$ 是距离函数, 第一版建议用 cosine distance 或 Euclidean distance; $\text{Normalize}(\cdot)$ 表示把同一个 source-target 成本矩阵缩放到 $[0, 1]$ 。

SR 成本为:

$$C_{ij}^{\text{SR}} = \text{Normalize}(|s_i - s_j|). \quad (11)$$

这里, C_{ij}^{SR} 表示 source 节点 i 和 target 节点 j 的 SR 差异成本。

最终成本矩阵为:

$$C_{ij} = \frac{\lambda_{\text{struct}} C_{ij}^{\text{struct}} + \lambda_{\text{SR}} C_{ij}^{\text{SR}}}{\lambda_{\text{struct}} + \lambda_{\text{SR}}}. \quad (12)$$

这里, C_{ij} 是送入 OT 的总成本; λ_{struct} 是结构成本权重; λ_{SR} 是 SR 成本权重。第一版可以设 $\lambda_{\text{struct}} = 1$ 、 $\lambda_{\text{SR}} = 0.5$ 或者二者都设为 1 做对照。

4.3 OT kernel

设 n_s 是 source 节点数量, n_t 是 target 节点数量, 令 $a_i = 1/n_s$ 、 $b_j = 1/n_t$ 分别表示均匀 source mass 和 target mass。熵正则 OT 求解:

$$P^* = \arg \min_{P \in \mathcal{U}(a,b)} \sum_{i=1}^{n_s} \sum_{j=1}^{n_t} P_{ij} C_{ij} + \varepsilon \sum_{i=1}^{n_s} \sum_{j=1}^{n_t} P_{ij} (\log P_{ij} - 1). \quad (13)$$

这里, P^* 是未行归一化的 OT coupling; $\mathcal{U}(a,b) = \{P \geq 0 : P\mathbf{1} = b, P^\top \mathbf{1} = a\}$ 表示满足边际分布约束的非负矩阵集合; ε 是熵正则强度; $\mathbf{1}$ 是全 1 向量。

为了和当前 MIGNet 指标接口一致, 最后使用行归一化的 PIJ kernel:

$$\hat{P}_{ij} = \frac{P_{ij}^*}{\sum_{j'=1}^{n_t} P_{ij'}^*}. \quad (14)$$

这里, $\hat{P}_{ij}$ 表示 source 节点 i 转移到 target 节点 j 的条件概率。

5 JointNMF + SR: 作为第二条轻量路线

5.1 为什么不能直接复用现在的大矩阵

现有 `joint_nmf` 会对 `context.lower_mats / context.upper_mats` 做 joint NMF。若沿用 `clean_expression_cci_mix`, 输入仍然是“表达基因 + CCI LR”的大矩阵, 计算量不会真正降下来。因此 JointNMF 这条线要配合一个紧凑 CCI/DDI 特征矩阵。

5.2 紧凑 CCI/DDI 矩阵

选取一个 LR 子集 $\mathcal{Q}^* \subseteq \mathcal{Q}$ 。为了避免数据泄露, $\mathcal{Q}^*$ 最好来自外部 LR 数据库、manifest 固定顺序, 或者只由 source time 决定; 不要根据所有 target time 的强度筛 top LR。

对节点 i 和 LR pair $q \in \mathcal{Q}^*$, 定义 outgoing 和 incoming 特征:

$$X_{i,(q,\text{out})} = \sum_j \widetilde{M}_{ij}^{(q)}, \quad X_{i,(q,\text{in})} = \sum_j \widetilde{M}_{ji}^{(q)}. \quad (15)$$

这里, X 是非负的 node-by-feature 矩阵; $X_{i,(q,\text{out})}$ 表示节点 i 通过 LR pair q 发出的总通信强度; $X_{i,(q,\text{in})}$ 表示节点 i 通过 LR pair q 接收的总通信强度。

5.3 泄露安全的 NMF 方式

对一个 transition $t_0 \rightarrow t_1$, source 矩阵记为 X_{t_0} , target 矩阵记为 X_{t_1} 。先只在 source 上学习字典:

$$X_{t_0} \approx W_{t_0} H_{t_0}. \quad (16)$$

这里, $W_{t_0} \in \mathbb{R}_{\geq 0}^{n_s \times K}$ 是 source 节点的 NMF 表征; $H_{t_0} \in \mathbb{R}_{\geq 0}^{K \times p}$ 是 source 学到的非负字典; p 是紧凑特征维度; K 是 NMF latent component 数。

然后固定 H_{t_0} , 把 target 投影到同一个字典上:

$$W_{t_1}^* = \arg \min_{W \geq 0} \|X_{t_1} - W H_{t_0}\|_F^2 + \alpha \|W\|_F^2. \quad (17)$$

这里, $W_{t_1}^*$ 是 target 节点在 source 字典下的表征; $\|\cdot\|_F$ 是 Frobenius 范数; α 是可选的 ridge 稳定项。

节点结构向量定义为:

$$z_i^{\text{nmf}} = W(i, :), \quad (18)$$

其中, $W(i, :)$ 表示矩阵 W 的第 i 行。之后的 C_{ij}^{struct} 、 C_{ij}^{SR} 、 C_{ij} 和 $\hat{P}_{ij}$ 与 Laplacian+SR 完全相同。

如果使用传统 temporal joint NMF: $\min_{\{W_t\}, H} \sum_t \|X_t - W_t H\|_F^2$, 它会让所有时间点共同决定字典 H 。这对描述性分析可以接受, 但若强调 transition prediction 或防止 target 泄露, 第一版不建议作为主结果。

6 代码改动建议

6.1 新增网络 builder

建议新增文件: `mignet_ce/networks/clean_cci_ddi_graph.py`。

该 builder 可以复用 `clean_expression_cci_mix` 的以下逻辑: 路径检查、表达 h5ad 读取、assignment 读取、`build_layer_cci_graph`、`overlap/coverage/spot correspondence`、`native_units` 对齐。但要删掉或绕过以下重步骤:

- 不构造完整 `expr_block`。
- 不构造全量 `build_native_graph_matrix`。
- 不做 `hstack([expr_block, cci_mat])`。
- 默认不导出 raw native features。

输出的 `NetworkContext` 保留:

- `lower_graphs / upper_graphs`: 供 Laplacian-HKS 使用。
- `lower_mats / upper_mats`: 只放紧凑 CCI/DDI 特征矩阵, 供 JointNMF 使用。
- `feature_alignment_space="native_units"`: 避免 lower 先投影到 upper。
- `metadata`: 标记 `uses_grn=False`、`uses_cci=True`, 并说明 domain 层按 DDI 解释。

6.2 新增两个 PIJ 方法

建议新增：

- `mignet_ce/pij/laplacian_sr_ot.py`
- `mignet_ce/pij/joint_nmf_sr_ot.py`

逻辑是：

1. 先构造低维结构表征 `MethodResult`：Laplacian-HKS 或 leakage-safe JointNMF。
2. 再调用已有的 `run_ot_pij_method_with_result`。
3. `component_builder` 返回两个成本项：`structure` 和 `sr`。
4. 成本权重使用新增参数，例如 `--pij-struct-weight` 和现有 `--pij-sr-weight`。

6.3 注册与配置

需要改动：

- `mignet_ce/networks/registry.py`: 注册 `clean_cci_ddi_graph`。
- `mignet_ce/pij/registry.py`: 注册 `laplacian_sr_ot`、`joint_nmf_sr_ot`。
- `mignet_ce/config.py`: 加入两个 PIJ 方法，并新增 `graph_sr_pilot preset`。
- `scripts/run_mignet_vertical_ablation.py`: 暴露 Laplacian-HKS 参数、compact LR feature 参数和 structure weight 参数。

7 建议的第一轮实验矩阵

第一轮不建议全量铺开。先做 heart + adjacent level pairs + 11.5 到 12.5，确认输出能稳定产生。

项目	建议设置
network	<code>clean_cci_ddi_graph</code>
pij methods	<code>laplacian_sr_ot</code> , <code>joint_nmf_sr_ot</code> ; 对照 <code>laplacian</code> , <code>joint_nmf</code> , <code>sr_ot</code>
organs	先只跑 heart，稳定后再跑 brain/lung
time points	先跑 11.5 12.5，稳定后再跑 11.5 12.5 13.5 14.5
level pairs	先跑 adjacent 三组: spot 到 less_than5, less_than5 到 k150, k150 到 k40
Laplacian	$K = 8$ 到 16; HKS diffusion scales $H = 8$ 左右
JointNMF	$K = 8$ 到 16; LR compact features 先取 300 或 500 个 LR pair
OT	$\varepsilon = 0.05$ ，先不用 unbalanced OT; cost metric 用 cosine 或 Euclidean 做小对照
导出	先只导出 metrics 和必要 metadata; 不要导出 raw native features

8 这版方案的优点与风险

8.1 优点

- **计算更轻**: Laplacian-HKS 直接从稀疏图出发, 避免 node-by-gene 大矩阵。JointNMF 也只吃紧凑 CCI/DDI 特征, 而不是表达基因和全量 LR 组合。
- **网络语义更干净**: cell 层是 CCI, domain 层是 DDI, 不再把 GRN 和 CCI 乘在一起。
- **防泄露更明确**: feature 在 native units 上独立构造, lower 不预投影到 upper; JointNMF 字典可以只从 source time 学; LR schema 不从 target 强度筛选。
- **和现有框架兼容**: 仍然产出 MethodResult 和 TransitionKernels, 后续 EI、DI、TE 逻辑不用大改。

8.2 风险

- **OT 矩阵仍然是二次复杂度**: 即使特征很轻, source-target 成本矩阵仍是 $n_s \times n_t$ 。spot 层如果节点太多, PIJ 本身仍会重。
- **Laplacian 普通 eigenvector 不一定跨图可比**: 因此建议用 HKS 或至少做 sign anchoring。普通 Laplacian embedding 可作为快速 sanity check, 不建议直接作为主结果。
- **JointNMF 的字典策略会影响结果**: transductive joint NMF 可能更稳定但有 target 泄露嫌疑; source-only dictionary 更干净但可能拟合弱。
- **SR 数据质量会变成关键**: 如果 domain 级 SR 来自 spot 聚合, 聚合方式 mean/median 会影响 PIJ, 需要记录在 metadata 中。

9 最终建议

我建议第一版按如下优先级推进:

1. 先实现 clean_cci_ddi_graph, 保证同一份 CCI/DDI 图可以被 Laplacian 和 JointNMF 复用。
2. 先实现 laplacian_sr_ot, 优先用 Laplacian-HKS, 而不是普通 eigenvector 坐标。
3. 再实现 joint_nmf_sr_ot, 使用 compact LR in/out features, 并默认 source-only dictionary, 避免 target time 参与字典学习。
4. 第一轮只跑 heart + adjacent pairs + 11.5→12.5。若 EI/DI 指标和 runtime 都正常, 再扩展到全部器官、全部时间点、全部层级对。

这不是要彻底放弃 clean_expression_cci_mix, 而是把它作为结构参考: 路径解析、CCI 建图、native units、overlap/coverage 都沿用; 但把大表达特征矩阵从第一版中拿掉, 先验证 CCI/DDI 结构 + SR 是否能给出可解释的因果涌现信号。