

Light CCI 与 compare 矩阵

数学原理讲解稿

表达表征 / 拉普拉斯结构表征 / 发育潜能表征 / 联合非负
矩阵分解表征

报告定位。这份报告用于今天下午讲代码背后的方法原理，但正文不按代码讲，而按“数学对象如何被构造、为什么这样构造、最后如何得到跨时间转移矩阵与有效信息增益”来讲。报告不使用任何代码变量名、函数名或文件路径，只用数学符号和描述性语言。新版在原来的表达表征、拉普拉斯结构表征、发育潜能表征之外，补充了**联合非负矩阵分解表征**，也就是你口头提到的 Joint MMF/Joint NMF 那一块；从实现含义看，这里讲的是 Joint NMF，即联合非负矩阵分解。

核心结论

一句话总览：Light CCI 先把每一个时间点、每一个层级转成一张“生物关系图”：基因层使用基因调控网络，spot 与 domain 层使用细胞通讯网络。compare 组再从这些图和外部表达/发育特征中提取四类表征：表达模式、图结构热核、发育潜能、矩阵分解潜变量。之后在任意两个时间点之间构造行归一化的转移矩阵 P ，最后比较微观层与宏观层的有效信息。

生成日期：2026-07-09

项目：2026 因果涌现

用途：组会/课堂式方法讲解

目录

1 先把整件事讲成一个数学流程	4
1.1 研究问题：跨时间的单位应该如何对应	4
1.2 微观层与宏观层是分开做同一件事	4
1.3 总流程分成三步	5
2 Light CCI：每个层级先成为一张生物关系图	5
2.1 Light CCI 的核心原则	5
2.2 spot 与 domain 层：从 CCI 得到邻接矩阵	5
2.3 基因层：从 GRN 得到邻接矩阵	6
2.4 Light CCI 的输出本质	6
3 compare 组的公共框架：从单位特征到跨时间矩阵	6
3.1 每个单位先变成一个特征向量	6
3.2 多个表征先标准化再拼接	7
4 表达表征：用表达模式描述单位	7
4.1 表达表征想回答什么问题	7
4.2 spot/domain 层的表达矩阵	7
4.3 基因层的特殊表达表征：基因乘 spot 的模式	8
5 拉普拉斯结构表征：用图热扩散描述结构位置	9
5.1 拉普拉斯结构表征想回答什么问题	9
5.2 先把有向图变成可做拉普拉斯的无向强度图	9
5.3 归一化拉普拉斯	9
5.4 从拉普拉斯谱到热核签名	10
6 发育潜能表征：用 SR 描述单位状态	10
6.1 发育潜能表征想回答什么问题	10
6.2 spot/domain 层的 SR	10
6.3 基因层的 SR：由表达加权分配	11
7 联合非负矩阵分解表征：用网络潜模块描述单位	11
7.1 这一块到底在解决什么问题	11
7.2 矩阵分解表征的输入：两张非负邻接矩阵	12

7.3	普通时间对联合非负矩阵分解：适用于非 spot 层	12
7.4	普通联合分解的节点特征是什么	12
7.5	普通联合分解的乘法更新	13
7.6	为什么 spot 层要用共享核心有向分解	13
7.7	共享核心分解的节点特征是什么	14
7.8	共享核心有向分解的乘法更新	15
7.9	为什么矩阵分解要按时间对单独做	15
7.10	矩阵分解特征如何标准化	16
7.11	矩阵分解特征和其他表征如何组合	16
8	从特征到跨时间转移矩阵：三种机制	17
8.1	统一记号	17
8.2	余弦核：越同向，转移概率越大	17
8.3	KL 核：把特征向量先变成分布再比较	17
8.4	稀疏半松弛最优传输：在局部候选边上做全局分配	18
9	实验矩阵该怎么讲	18
9.1	单特征实验	19
9.2	两两组合实验	19
9.3	三种构造 P 的后缀应该怎么解释	19
10	有效信息：为什么最后看宏观层减微观层	19
10.1	从转移矩阵到有效信息	20
10.2	有效信息增益	20
11	今天汇报时可以按这个顺序讲	20
11.1	建议讲述顺序	20
11.2	每一块的一句话总结	21
12	可能被问到的问题与回答	21
12.1	为什么 Light CCI 里面基因层不用 CCI?	21
12.2	为什么表达表征在基因层要用基因乘 spot 矩阵?	21
12.3	为什么拉普拉斯表征要用热核签名而不是直接用邻接行?	21
12.4	SR 给基因的公式会不会是在算相关性?	22
12.5	为什么矩阵分解表征要对每个时间对单独做?	22
12.6	普通联合非负矩阵分解和共享核心有向分解有什么区别?	22

12.7 为什么稀疏最优传输比简单余弦核更强?	22
13 一页口头版总结	22

1 先把整件事讲成一个数学流程

1.1 研究问题：跨时间的单位应该如何对应

我们手里不是只有一个时间点，而是一串发育时间点。每一个时间点都有多个层级，例如基因层、spot 层、较小 domain 层、较大 domain 层。每个层级都有许多单位：基因层的单位是基因，spot 层的单位是空间位置上的 spot，domain 层的单位是由若干 spot 聚合得到的区域。

compare 组真正要做的事情，是在同一个层级内部，给出从早期时间点到晚期时间点的“单位对应关系”。这种对应关系不是硬匹配，而是一个概率矩阵：早期第 i 个单位可以以不同强度连接到晚期第 j 个单位。

跨时间转移矩阵

$$P_{ij}^{s \rightarrow t} \geq 0, \quad \sum_{j=1}^{n_t} P_{ij}^{s \rightarrow t} = 1.$$

符号说明：这里 s 表示源时间点，也就是较早时间点； t 表示目标时间点，也就是较晚时间点； i 表示源时间点中的一个单位编号； j 表示目标时间点中的一个单位编号； n_t 表示目标时间点的单位数量； $P_{ij}^{s \rightarrow t}$ 表示源时间点第 i 个单位转移到目标时间点第 j 个单位的概率或权重。约束 $P_{ij}^{s \rightarrow t} \geq 0$ 表示权重不能为负；约束 $\sum_{j=1}^{n_t} P_{ij}^{s \rightarrow t} = 1$ 表示每一个源单位的一整行转移概率加起来必须等于一。

讲的时候可以这样说

可以先说：我们不是让早期一个单位只对应晚期一个单位，而是让它对应一个分布。这个分布就是 P 的一行。行越尖锐，说明这个早期单位的未来去向越明确；行越平均，说明未来去向越模糊。

1.2 微观层与宏观层是分开做同一件事

对一个垂直层级对来说，会同时有一个相对微观的层级和一个相对宏观的层级。比如基因到 spot、spot 到 domain、较小 domain 到较大 domain。compare 方法会为两个层级分别构造跨时间转移矩阵，然后用有效信息比较哪个层级在跨时间映射上更有结构、更少模糊。

微观层与宏观层的两个转移矩阵

$$P_{\text{micro}}^{s \rightarrow t} \in \mathbb{R}^{n_s^{\text{micro}} \times n_t^{\text{micro}}}, \quad P_{\text{macro}}^{s \rightarrow t} \in \mathbb{R}^{n_s^{\text{macro}} \times n_t^{\text{macro}}}.$$

符号说明：这里 $P_{\text{micro}}^{s \rightarrow t}$ 表示微观层从时间点 s 到时间点 t 的转移矩阵； $P_{\text{macro}}^{s \rightarrow t}$ 表示宏观层从时间点 s 到时间点 t 的转移矩阵； n_s^{micro} 表示源时间点微观层单位数量； n_t^{micro} 表示目标时间点微观层单位数量； n_s^{macro} 表示源时间点宏观层单位数量； n_t^{macro} 表示目标时间点宏观层单位数量； $\mathbb{R}^{a \times b}$ 表示所有 a 行 b 列实数矩阵构成的空间。

1.3 总流程分成三步

1. **每层每时间点先建图**。基因层得到基因调控图；spot 和 domain 层得到细胞通讯图。图的邻接矩阵记录单位之间的正向关系强度。
2. **每个单位变成特征向量**。特征可以来自表达模式、图拉普拉斯热核、发育潜能、或者联合非负矩阵分解潜变量。
3. **由特征构造跨时间转移矩阵**。特征相似的早晚单位之间得到更高转移概率；最后把微观层与宏观层的转移矩阵放入有效信息公式。

2 Light CCI: 每个层级先成为一张生物关系图

2.1 Light CCI 的核心原则

Light CCI 的核心不是把所有东西混进同一个向量，而是先承认不同层级有不同的“生物关系语义”。基因层的关系是调控关系；spot 或 domain 层的关系是细胞通讯关系。因此每个时间点、每个层级都先被表示成一张有向加权图。

每个时间点、每个层级的一张图

$$G_t^{(\ell)} = \left(V_t^{(\ell)}, E_t^{(\ell)}, A_t^{(\ell)} \right).$$

符号说明：这里 ℓ 表示层级，例如 gene、spot 或 domain； t 表示一个发育时间点； $G_t^{(\ell)}$ 表示时间点 t 上层级 ℓ 的图； $V_t^{(\ell)}$ 表示这个图的节点集合，也就是该时间点该层级的所有单位； $E_t^{(\ell)}$ 表示边集合，也就是单位之间存在的关系； $A_t^{(\ell)}$ 表示邻接矩阵，其第 i 行第 j 列记录从单位 i 指向单位 j 的关系强度。

核心结论

Light CCI 的“light”可以理解为：先只保留最核心的层级关系图，不把空间、表达、发育时间等东西提前混在图节点特征里。后面的 compare 表征再有选择地加入表达、结构、发育潜能或矩阵分解信息。

2.2 spot 与 domain 层：从 CCI 得到邻接矩阵

在 spot 或 domain 层，节点是空间 spot 或 domain 区域。边来自细胞通讯强度。直观地说，如果单位 u 的配体信号能够影响单位 v 的受体信号，那么从 u 到 v 就有一条有向边。

CCI 邻接矩阵

$$A_{t,uv}^{(\ell)} = \sum_{r \in \mathcal{R}} C_{uv}^{(\ell,t,r)}, \quad A_{t,uv}^{(\ell)} \geq 0.$$

符号说明：这里 ℓ 表示 spot 或 domain 层级； t 表示时间点； u 表示源单位； v 表示目标单位； $A_{t,uv}^{(\ell)}$ 表示时间点 t 上层级 ℓ 中从单位 u 到单位 v 的总通讯强度； $\mathcal{R}$ 表示所有可用的配体-受体关系集合； r 表示其中一对具体配体-受体关系； $C_{uv}^{(\ell,t,r)}$ 表示在时间点 t 、层级 ℓ 、配体-受体关系 r 下，从 u 到 v 的通讯分数。求和表示把所有配体-受体通道的通讯强度加起来，形成总 CCI 图。

2.3 基因层：从 GRN 得到邻接矩阵

基因层不使用 CCI，因为 CCI 是细胞或区域之间的通信，而不是基因与基因之间的通信。基因层使用 GRN，即基因调控网络。节点是基因，边是调控因子到靶基因的关系。

GRN 邻接矩阵

$$A_{t,gh}^{(\text{gene})} = |w_{g \rightarrow h}^{(t)}|.$$

符号说明：这里 $A_{t,gh}^{(\text{gene})}$ 表示时间点 t 上基因层从基因 g 到基因 h 的边强度； g 表示作为调控因子的源基因； h 表示作为靶标的目标基因； $w_{g \rightarrow h}^{(t)}$ 表示时间点 t 上从基因 g 到基因 h 的原始调控权重；绝对值符号 $|\cdot|$ 表示这里只使用调控强度大小，而不把正负号作为边强度的方向含义。

讲的时候可以这样说

这一段可以强调：Light CCI 不是“所有层级都用 CCI”。它的语义是“每个层级用最自然的关系图”。基因层自然是 GRN，spot/domain 层自然是 CCI。

2.4 Light CCI 的输出本质

Light CCI 输出的不是用于 compare 的最终特征，而是每个时间点、每个层级的一张非负有向图。后续的 E、L、SR、N 表征，都是在这些图或外部表格上继续构造。

非负邻接矩阵集合

$$\mathcal{A}^{(\ell)} = \{A_{t_1}^{(\ell)}, A_{t_2}^{(\ell)}, \dots, A_{t_T}^{(\ell)}\}, \quad A_{t_q}^{(\ell)} \in \mathbb{R}_{\geq 0}^{n_{t_q}^{(\ell)} \times n_{t_q}^{(\ell)}}.$$

符号说明：这里 $\mathcal{A}^{(\ell)}$ 表示层级 ℓ 在所有时间点上的邻接矩阵集合； $t_1, t_2, \dots, t_T$ 表示共有 T 个时间点； $A_{t_q}^{(\ell)}$ 表示第 q 个时间点上层级 ℓ 的邻接矩阵； $n_{t_q}^{(\ell)}$ 表示第 q 个时间点层级 ℓ 的节点数量； $\mathbb{R}_{\geq 0}^{a \times b}$ 表示所有 a 行 b 列的非负实数矩阵。

3 compare 组的公共框架：从单位特征到跨时间矩阵

3.1 每个单位先变成一个特征向量

不管使用表达表征、拉普拉斯表征、发育潜能表征，还是联合非负矩阵分解表征，最终都要把时间点 t 上某一层级的每个单位 i 表示成一个向量。

单位特征矩阵

$$Z_t^{(\ell)} = \begin{bmatrix} - & \mathbf{z}_{t,1}^{(\ell)} & - \\ - & \mathbf{z}_{t,2}^{(\ell)} & - \\ & \vdots & \\ - & \mathbf{z}_{t,n_t}^{(\ell)} & - \end{bmatrix} \in \mathbb{R}^{n_t^{(\ell)} \times d}.$$

符号说明：这里 $Z_t^{(\ell)}$ 表示时间点 t 上层级 ℓ 的特征矩阵； $\mathbf{z}_{t,i}^{(\ell)}$ 表示时间点 t 上层级 ℓ 中第 i 个单位的特征向量； $n_t^{(\ell)}$ 表示该时间点该层级的单位数量； d 表示特征维度；矩阵中每一行对应一个单位，每一列对应一个特征坐标。

3.2 多个表征先标准化再拼接

如果同时使用多个表征，例如表达加拉普拉斯，或者表达加矩阵分解，不能直接把原始值拼起来，因为不同表征的数值尺度不同。compare 组先对每一种基础表征做标准化，再乘以权重的平方根，最后拼接。

标准化与加权拼接

$$\tilde{Z}_{t,ik}^{(m)} = \frac{Z_{t,ik}^{(m)} - \mu_k^{(m)}}{\sigma_k^{(m)}}, \quad Z_t^{\text{combo}} = \left[\sqrt{\lambda_1} \tilde{Z}_t^{(1)}, \sqrt{\lambda_2} \tilde{Z}_t^{(2)}, \dots, \sqrt{\lambda_M} \tilde{Z}_t^{(M)} \right].$$

符号说明：这里 m 表示第 m 种基础表征； $Z_{t,ik}^{(m)}$ 表示时间点 t 上第 i 个单位在第 m 种表征的第 k 个坐标； $\mu_k^{(m)}$ 表示第 m 种表征第 k 个坐标的均值； $\sigma_k^{(m)}$ 表示第 m 种表征第 k 个坐标的标准差； $\tilde{Z}_{t,ik}^{(m)}$ 表示标准化后的值； λ_m 表示第 m 种表征的非负权重； Z_t^{combo} 表示拼接后的组合特征矩阵；方括号 $[\dots]$ 表示按列拼接。

为什么用 $\sqrt{\lambda_m}$ 而不是 λ_m

后面距离常常是二范数、余弦距离或由向量差异诱导的代价。若某个特征块被乘以 $\sqrt{\lambda_m}$ ，那么它在平方型距离中的贡献大约按 λ_m 放大，而不是按 λ_m^2 放大。这样更符合“权重就是贡献比例”的直觉。

4 表达表征：用表达模式描述单位

4.1 表达表征想回答什么问题

表达表征问的是：两个单位是否处在相似的分子表达状态。对于 spot 或 domain，单位天然有一条表达向量；对于基因层，基因本身不是细胞，因此不能把“一个基因的表达标量”直接当成丰富特征，而要把一个基因在所有 spot 上的表达模式看成它的特征。

4.2 spot/domain 层的表达矩阵

对非基因层，一个单位 u 的表达表征就是它在共享基因集合上的表达向量。

非基因层表达表征

$$X_t^{(\ell)}(u, g) = \text{单位 } u \text{ 在基因 } g \text{ 上的表达量}, \quad \mathbf{x}_{t,u}^{(\ell)} = \left(X_t^{(\ell)}(u, g_1), \dots, X_t^{(\ell)}(u, g_p) \right).$$

符号说明：这里 ℓ 表示非基因层，例如 spot 或 domain； t 表示时间点； u 表示该层级中的一个单位； g 表示一个基因； $g_1, \dots, g_p$ 表示被选中的 p 个共享基因； $X_t^{(\ell)}(u, g)$ 表示单位 u 在基因 g 上的表达量； $\mathbf{x}_{t,u}^{(\ell)}$ 表示单位 u 的表达向量。

表达矩阵会经过常规预处理：按单位总表达量归一化、取 $\log(1+x)$ 、按基因选择高变或指定数量的基因、标准化，然后在需要时做低维降维。其作用是避免单个大表达量基因或测序深度差异支配全部距离。

4.3 基因层的特殊表达表征：基因乘 spot 的模式

基因层最容易出问题：一个基因在某个时间点如果只给一个平均表达量，那么每个基因只有一个标量，无法形成有意义的跨时间几何。新版逻辑把基因看成“在空间 spot 上展开的一条表达模式”。

基因乘 spot 的表达模式矩阵

$$M_t^{(\text{gene})}(g, s) = X_t^{(\text{spot})}(s, g).$$

符号说明：这里 $M_t^{(\text{gene})}$ 表示时间点 t 上基因层的表达模式矩阵； g 表示一个基因； s 表示一个 spot； $X_t^{(\text{spot})}(s, g)$ 表示时间点 t 上 spot s 对基因 g 的表达量；因此 $M_t^{(\text{gene})}(g, s)$ 表示基因 g 在 spot s 处的表达强度。这个矩阵的每一行是一个基因，每一列是一个 spot。

随后对每个时间点的基因乘 spot 矩阵做主成分压缩。默认目标维度是 64 维；如果某个时间点的基因数或 spot 数不足 64，则实际可估计的主成分数会变少，剩余维度补零，从而保证最终维度仍然统一。

基因表达模式的 PCA 压缩

$$Z_t^{(\text{gene}, E)} = M_t^{(\text{gene})} Q_t, \quad Z_t^{(\text{gene}, E)} \in \mathbb{R}^{n_t^{(\text{gene})} \times d_E}.$$

符号说明：这里 $Z_t^{(\text{gene}, E)}$ 表示时间点 t 上基因层的表达表征矩阵； $M_t^{(\text{gene})}$ 表示基因乘 spot 的表达模式矩阵； Q_t 表示时间点 t 上由主成分分析得到的投影方向矩阵； $n_t^{(\text{gene})}$ 表示时间点 t 上基因节点数量； d_E 表示表达表征目标维度，当前设计中取 64；矩阵乘法表示把每个基因的空间表达模式压缩到 d_E 维。

因为每个时间点单独做 PCA，主成分方向可能会旋转。为使不同时间点的基因表达坐标可比较，需要把后续时间点的 PCA 坐标对齐到第一个时间点。

正交 Procrustes 时间对齐

$$R_t^* = \arg \min_{R^\top R = I} \left\| Z_t^{(\text{gene}, E)} R - Z_{t_1}^{(\text{gene}, E)} \right\|_F^2, \quad \hat{Z}_t^{(\text{gene}, E)} = Z_t^{(\text{gene}, E)} R_t^*.$$

符号说明：这里 R_t^* 表示时间点 t 的最优正交旋转矩阵； $R^\top R = I$ 表示 R 是正交矩阵，旋转后不改变距离尺度； $\|\cdot\|_F$ 表示 Frobenius 范数，也就是矩阵元素平方和再开方； $Z_t^{(\text{gene}, E)}$ 表示原始 PCA 坐标； $Z_{t_1}^{(\text{gene}, E)}$ 表示第一个时间点的参考坐标； $\hat{Z}_t^{(\text{gene}, E)}$ 表示旋转对齐后的表达表征。

讲的时候可以这样说

这块可以重点讲：基因层不是“基因只有一个表达值”，而是“一个基因在所有 spot 上形成一个空间表达模式”。PCA 是把这个模式压成 64 维。这样基因层也有丰富的表达几何。

5 拉普拉斯结构表征：用图热扩散描述结构位置

5.1 拉普拉斯结构表征想回答什么问题

表达表征看的是分子状态，拉普拉斯结构表征看的是一个单位在生物关系图里的结构位置。两个单位即使表达相似，也可能在网络中处于完全不同的位置；拉普拉斯热核表征试图刻画“这个节点在图上的扩散环境像不像”。

5.2 先把有向图变成可做拉普拉斯的无向强度图

图拉普拉斯通常建立在无向图上。Light CCI 的图是有向图，因此先做对称化。

有向邻接矩阵的对称化

$$S_t = \frac{1}{2} (A_t + A_t^\top).$$

符号说明：这里 A_t 表示时间点 t 的原始有向邻接矩阵； $A_t^\top$ 表示 A_t 的转置矩阵，也就是把边方向反过来； S_t 表示对称化后的无向强度矩阵；系数 $1/2$ 表示取正反方向强度的平均。

5.3 归一化拉普拉斯

对称图的度数是每个节点连接强度的总和。归一化拉普拉斯用于削弱高度数节点对谱结构的支配。

度矩阵与归一化拉普拉斯

$$D_t(i, i) = \sum_j S_t(i, j), \quad L_t = I - D_t^{-1/2} S_t D_t^{-1/2}.$$

符号说明：这里 D_t 表示时间点 t 的度矩阵； $D_t(i, i)$ 表示第 i 个节点的度，也就是第 i 行所有边强度之和； $S_t(i, j)$ 表示对称化图中节点 i 与节点 j 的连接强度； L_t 表示归一化图拉普拉斯； I 表示单位矩阵； $D_t^{-1/2}$ 表示把每个节点度数开方后取倒数形成的对角矩阵。

5.4 从拉普拉斯谱到热核签名

拉普拉斯的特征值和特征向量描述图上的扩散模式。热核签名把这些模式在多个扩散时间尺度上组合起来，得到每个节点的结构指纹。

拉普拉斯谱分解

$$L_t \phi_{t,k} = \lambda_{t,k} \phi_{t,k}.$$

符号说明：这里 L_t 表示时间点 t 的归一化拉普拉斯； $\lambda_{t,k}$ 表示第 k 个特征值； $\phi_{t,k}$ 表示第 k 个特征向量；等式表示 $\phi_{t,k}$ 是图扩散系统的一个基本模式， $\lambda_{t,k}$ 控制该模式随热扩散衰减的速度。

热核签名

$$H_t(i, \tau) = \sum_k e^{-\lambda_{t,k} \tau} \phi_{t,k}(i)^2.$$

符号说明：这里 $H_t(i, \tau)$ 表示时间点 t 中节点 i 在扩散时间尺度 τ 下的热核签名； τ 表示热扩散时间， τ 小时关注局部邻域， τ 大时关注更全局的结构； $\lambda_{t,k}$ 表示第 k 个拉普拉斯特征值； $\phi_{t,k}(i)$ 表示第 k 个特征向量在节点 i 上的取值；平方 $\phi_{t,k}(i)^2$ 表示节点 i 在第 k 个扩散模式中的参与强度。

6 发育潜能表征：用 SR 描述单位状态

6.1 发育潜能表征想回答什么问题

SR 表征想回答：一个单位在发育进程中处于更“原始/高潜能”还是更“分化/低潜能”的状态。它不是图结构特征，也不是空间特征，而是来自外部发育特征文件中的单位级发育潜能分数。

6.2 spot/domain 层的 SR

对于 spot 或 domain 层，如果该层级已经有 SR 分数，直接把每个单位的 SR 作为一维特征。

单位级 SR 特征

$$Z_t^{(\text{SR})}(u) = r_t(u).$$

符号说明：这里 $Z_t^{(\text{SR})}(u)$ 表示时间点 t 上单位 u 的 SR 表征； $r_t(u)$ 表示该单位在外部发育特征表中的 SR 分数；这个公式说明 SR 表征是一维数值特征。

6.3 基因层的 SR：由表达加权分配

基因本身没有直接的 spot 级 SR 分数。新版逻辑不是算 SR 相关性，而是用基因表达量作为权重，把 spot 的 SR 加权分配给基因。一个基因如果主要在高 SR 的 spot 表达，它获得较高的基因级 SR；如果主要在低 SR 的 spot 表达，它获得较低的基因级 SR。

表达加权的基因级 SR

$$R_t(g) = \frac{\sum_{s \in \mathcal{S}_t} X_t(s, g) r_t(s)}{\sum_{s \in \mathcal{S}_t} X_t(s, g) + \varepsilon}.$$

符号说明：这里 $R_t(g)$ 表示时间点 t 上基因 g 的基因级 SR； $\mathcal{S}_t$ 表示时间点 t 的所有 spot 集合； s 表示其中一个 spot； $X_t(s, g)$ 表示 spot s 上基因 g 的表达量； $r_t(s)$ 表示 spot s 的 SR 分数； ε 表示一个很小的正数，用来避免分母为零。分子是“表达量乘 SR”的加权和，分母是该基因在所有 spot 上的总表达量。

讲的时候可以这样说

可以强调：这不是相关性。相关性要比较两条向量的共同变化；这里是加权平均。表达高的 spot 对这个基因的 SR 贡献更大，表达低的 spot 贡献更小。

7 联合非负矩阵分解表征：用网络潜模块描述单位

7.1 这一块到底在解决什么问题

表达表征看分子表达，拉普拉斯表征看谱扩散位置，SR 表征看发育潜能。联合非负矩阵分解表征问的是另一个问题：一个节点在关系网络中属于哪些潜在通讯模块、调控模块或结构模块？

邻接矩阵的一行可以看成一个节点指向其他节点的完整连接模式，但这通常非常高维、稀疏、噪声大。非负矩阵分解的思想是：把高维连接模式压缩成少量非负模块。每个节点不再直接用几千维邻接行表示，而是用几个模块强度表示。

核心结论

新版矩阵分解表征不是对四个时间点一起做一个全局模型，而是对每一对时间点单独做。给定源时间点 s 和目标时间点 t ，只使用这两个时间点的邻接矩阵来分解，并只在这一对时间点内部使用分解得到的节点特征。因此它是“time-pair specific”的表征。

7.2 矩阵分解表征的输入：两张非负邻接矩阵

对于一个层级 ℓ 和一个时间对 (s, t) ，我们取源时间点的邻接矩阵和目标时间点的邻接矩阵。

时间对上的两张邻接矩阵

$$A_s \in \mathbb{R}_{\geq 0}^{n_s \times m_s}, \quad A_t \in \mathbb{R}_{\geq 0}^{n_t \times m_t}.$$

符号说明：这里 A_s 表示源时间点 s 的非负邻接矩阵； A_t 表示目标时间点 t 的非负邻接矩阵； n_s 表示源时间点的节点数量； n_t 表示目标时间点的节点数量； m_s 表示源矩阵的列数； m_t 表示目标矩阵的列数； $\mathbb{R}_{\geq 0}^{a \times b}$ 表示所有 a 行 b 列的非负实数矩阵。

对于普通联合非负矩阵分解，需要 $m_s = m_t$ ，也就是两张矩阵的列空间一致；对于 spot 层，因为不同时间点的 spot 数量经常不同，所以不能强行使用普通联合分解，而需要使用“共享核心”的有向矩阵分解。

7.3 普通时间对联合非负矩阵分解：适用于非 spot 层

普通联合非负矩阵分解的目标是让源时间点和目标时间点共享同一个列方向基底。也就是说，两个时间点都用同一个模块字典 H ，但每个时间点的节点有各自的模块权重 W_s 和 W_t 。

普通联合非负矩阵分解目标函数

$$\min_{W_s \geq 0, W_t \geq 0, H \geq 0} \|A_s - W_s H\|_F^2 + \|A_t - W_t H\|_F^2.$$

符号说明：这里 A_s 表示源时间点的非负邻接矩阵； A_t 表示目标时间点的非负邻接矩阵； W_s 表示源时间点节点的非负模块权重矩阵； W_t 表示目标时间点节点的非负模块权重矩阵； H 表示两个时间点共享的非负模块基底矩阵； $\|\cdot\|_F^2$ 表示 Frobenius 范数平方，也就是矩阵中所有元素误差平方求和；约束 $W_s \geq 0$ 、 $W_t \geq 0$ 、 $H \geq 0$ 表示三个矩阵所有元素都必须非负。

普通联合分解的矩阵形状

$$A_s \in \mathbb{R}_{\geq 0}^{n_s \times m}, \quad A_t \in \mathbb{R}_{\geq 0}^{n_t \times m}, \quad W_s \in \mathbb{R}_{\geq 0}^{n_s \times r}, \quad W_t \in \mathbb{R}_{\geq 0}^{n_t \times r}, \quad H \in \mathbb{R}_{\geq 0}^{r \times m}.$$

符号说明：这里 m 表示源时间点和目标时间点共享的列数； r 表示潜在模块数量，当前默认取 5； n_s 表示源时间点节点数量； n_t 表示目标时间点节点数量； A_s 和 A_t 是要被解释的邻接矩阵； W_s 和 W_t 是节点到模块的权重矩阵； H 是两个时间点共享的模块到列空间的基底矩阵。

7.4 普通联合分解的节点特征是什么

分解完成后，源时间点第 i 个节点的特征就是 W_s 的第 i 行；目标时间点第 j 个节点的特征就是 W_t 的第 j 行。

普通联合分解的节点特征

$$\mathbf{z}_{s,i}^{(N)} = W_s(i,:), \quad \mathbf{z}_{t,j}^{(N)} = W_t(j,:).$$

符号说明：这里 $\mathbf{z}_{s,i}^{(N)}$ 表示源时间点 s 上第 i 个节点的矩阵分解表征； $\mathbf{z}_{t,j}^{(N)}$ 表示目标时间点 t 上第 j 个节点的矩阵分解表征； $W_s(i,:)$ 表示矩阵 W_s 的第 i 行； $W_t(j,:)$ 表示矩阵 W_t 的第 j 行；上标 (N) 表示这是矩阵分解表征，不是表达、拉普拉斯或 SR 表征。

直观解释是： H 定义了几个共享网络模块， $W_s(i,:)$ 说明源时间点节点 i 分别使用这些模块的强度， $W_t(j,:)$ 说明目标时间点节点 j 分别使用这些模块的强度。于是两个时间点的节点可以在同一个潜在模块坐标系中比较。

7.5 普通联合分解的乘法更新

普通联合非负矩阵分解使用乘法更新。乘法更新的优点是：如果初始化为正数，那么更新后仍然非负。

更新源时间点节点权重

$$W_s \leftarrow W_s \odot \frac{A_s H^\top}{W_s H H^\top + \varepsilon}.$$

符号说明：这里 W_s 表示源时间点节点的模块权重矩阵； A_s 表示源时间点邻接矩阵； H 表示共享模块基底矩阵； $H^\top$ 表示 H 的转置； $\odot$ 表示逐元素相乘；分式表示逐元素相除； ε 表示一个很小的正数，用来避免除零。

更新目标时间点节点权重

$$W_t \leftarrow W_t \odot \frac{A_t H^\top}{W_t H H^\top + \varepsilon}.$$

符号说明：这里 W_t 表示目标时间点节点的模块权重矩阵； A_t 表示目标时间点邻接矩阵； H 表示源时间点和目标时间点共享的模块基底矩阵； $H^\top$ 表示 H 的转置； $\odot$ 表示逐元素相乘；分式表示逐元素相除； ε 表示防止除零的微小正数。

更新共享模块基底

$$H \leftarrow H \odot \frac{W_s^\top A_s + W_t^\top A_t}{(W_s^\top W_s + W_t^\top W_t)H + \varepsilon}.$$

符号说明：这里 H 表示共享模块基底矩阵； $W_s^\top$ 表示源时间点权重矩阵 W_s 的转置； $W_t^\top$ 表示目标时间点权重矩阵 W_t 的转置； A_s 和 A_t 分别表示源时间点和目标时间点的邻接矩阵；分子 $W_s^\top A_s + W_t^\top A_t$ 表示两个时间点共同给出的模块证据；分母 $(W_s^\top W_s + W_t^\top W_t)H + \varepsilon$ 表示当前模型对该证据的重建强度加稳定项； $\odot$ 表示逐元素相乘。

7.6 为什么 spot 层要用共享核心有向分解

spot 层的困难在于：不同时间点的 spot 数量通常不同，所以源时间点的邻接矩阵可能是 $n_s \times n_s$ ，目标时间点的邻接矩阵可能是 $n_t \times n_t$ ，其中 $n_s \neq n_t$ 。普通联合分解要求两

张矩阵列数相同，因此不适合直接用于 spot 层。

共享核心有向分解把每一张有向邻接矩阵分解成“出边角色、共享核心、入边角色”三部分。这样即使两个时间点节点数量不同，也可以共享同一个核心矩阵。

共享核心有向分解目标函数

$$\min_{U_s, V_s, U_t, V_t, B \geq 0} \|A_s - U_s B V_s^\top\|_F^2 + \|A_t - U_t B V_t^\top\|_F^2.$$

符号说明：这里 A_s 表示源时间点的有向邻接矩阵； A_t 表示目标时间点的有向邻接矩阵； U_s 表示源时间点节点的出边角色权重矩阵； V_s 表示源时间点节点的入边角色权重矩阵； U_t 表示目标时间点节点的出边角色权重矩阵； V_t 表示目标时间点节点的入边角色权重矩阵； B 表示源时间点和目标时间点共享的模块交互核心矩阵； $V_s^\top$ 和 $V_t^\top$ 表示入边角色矩阵的转置； $\|\cdot\|_F^2$ 表示重建误差平方和；非负约束表示所有潜在强度都不能为负。

共享核心分解的矩阵形状

$$A_s \in \mathbb{R}_{\geq 0}^{n_s \times n_s}, \quad A_t \in \mathbb{R}_{\geq 0}^{n_t \times n_t}, \quad U_s, V_s \in \mathbb{R}_{\geq 0}^{n_s \times r}, \quad U_t, V_t \in \mathbb{R}_{\geq 0}^{n_t \times r}, \quad B \in \mathbb{R}_{\geq 0}^{r \times r}.$$

符号说明：这里 n_s 表示源时间点 spot 数量； n_t 表示目标时间点 spot 数量； r 表示潜在模块数量，当前默认取 5； A_s 和 A_t 是两张不同大小的 spot 通讯邻接矩阵； U_s 和 V_s 是源时间点的出边与入边潜因子； U_t 和 V_t 是目标时间点的出边与入边潜因子； B 是两个时间点共享的模块交互矩阵。

7.7 共享核心分解的节点特征是什么

有向图中，一个节点可能既是信号发送者，也可能是信号接收者。这两个角色不一定一样。因此共享核心分解把节点特征定义为出边角色和入边角色的拼接。

spot 节点的矩阵分解特征

$$\mathbf{z}_{s,i}^{(N)} = [U_s(i, :), V_s(i, :)], \quad \mathbf{z}_{t,j}^{(N)} = [U_t(j, :), V_t(j, :)].$$

符号说明：这里 $\mathbf{z}_{s,i}^{(N)}$ 表示源时间点 spot i 的矩阵分解表征； $\mathbf{z}_{t,j}^{(N)}$ 表示目标时间点 spot j 的矩阵分解表征； $U_s(i, :)$ 表示源时间点 spot i 的出边角色向量； $V_s(i, :)$ 表示源时间点 spot i 的入边角色向量； $U_t(j, :)$ 表示目标时间点 spot j 的出边角色向量； $V_t(j, :)$ 表示目标时间点 spot j 的入边角色向量；方括号 $[\cdot, \cdot]$ 表示把两个向量按列拼接。若模块数为 r ，则该特征维度为 $2r$ 。

讲的时候可以这样说

这一段建议这样讲：普通 NMF 把节点的一行连接模式压成几个模块强度；spot 由于早晚 spot 数量不同，所以改用 $A \approx UBV^\top$ 。 U 代表“我像哪类发送者”， V 代表“我像哪类接收者”， B 代表发送模块和接收模块之间怎么相互作用。

7.8 共享核心有向分解的乘法更新

共享核心分解同样使用乘法更新。下面只写源时间点和共享核心的关键形式；目标时间点的 U_t 与 V_t 更新与源时间点完全同构。

更新源时间点出边角色

$$U_s \leftarrow U_s \odot \frac{A_s V_s B^\top}{U_s B (V_s^\top V_s) B^\top + \varepsilon}.$$

符号说明：这里 U_s 表示源时间点节点的出边角色矩阵； A_s 表示源时间点有向邻接矩阵； V_s 表示源时间点节点的入边角色矩阵； B 表示共享核心矩阵； $B^\top$ 表示共享核心矩阵的转置； $V_s^\top V_s$ 表示入边角色之间的内积矩阵； $\odot$ 表示逐元素相乘； ε 表示防止除零的微小正数。

更新源时间点入边角色

$$V_s \leftarrow V_s \odot \frac{A_s^\top U_s B}{V_s B^\top (U_s^\top U_s) B + \varepsilon}.$$

符号说明：这里 V_s 表示源时间点节点的入边角色矩阵； $A_s^\top$ 表示源时间点邻接矩阵的转置； U_s 表示源时间点节点的出边角色矩阵； B 表示共享核心矩阵； $U_s^\top U_s$ 表示出边角色之间的内积矩阵； $B^\top$ 表示 B 的转置； $\odot$ 表示逐元素相乘； ε 表示数值稳定项。

更新共享核心矩阵

$$B \leftarrow B \odot \frac{U_s^\top A_s V_s + U_t^\top A_t V_t}{(U_s^\top U_s) B (V_s^\top V_s) + (U_t^\top U_t) B (V_t^\top V_t) + \varepsilon}.$$

符号说明：这里 B 表示共享核心矩阵； U_s 和 V_s 分别表示源时间点的出边与入边角色矩阵； U_t 和 V_t 分别表示目标时间点的出边与入边角色矩阵； A_s 表示源时间点邻接矩阵； A_t 表示目标时间点邻接矩阵；分子 $U_s^\top A_s V_s + U_t^\top A_t V_t$ 表示两个时间点共同支持的模块交互证据；分母表示当前模型对这些模块交互证据的重建强度； ε 表示数值稳定项； $\odot$ 表示逐元素相乘。

7.9 为什么矩阵分解要按时间对单独做

这一点非常重要。矩阵分解表征不是对四个时间点一次性分解，而是对每一个 (s, t) 时间对独立分解。原因有三点。

1. **它只服务当前跨时间映射。**如果要构造从 s 到 t 的 $P^{s \rightarrow t}$ ，只需要让这两个时间点的潜模块坐标可比较。
2. **它避免把所有时间点强行拉到同一个列空间。**不同时间点可能节点数量不同，尤其 spot 层差异很大。
3. **它让矩阵分解的解释更干净。**每一个时间对都有自己的共享模块或共享核心，表示“这两个时间点之间可比较的网络模块”。

时间对特异的矩阵分解表征

$$\left(Z_{s|(s,t)}^{(N)}, Z_{t|(s,t)}^{(N)} \right) = \mathcal{F}_N(A_s, A_t).$$

符号说明：这里 $Z_{s|(s,t)}^{(N)}$ 表示为时间对 (s, t) 专门构造的源时间点矩阵分解特征； $Z_{t|(s,t)}^{(N)}$ 表示为时间对 (s, t) 专门构造的目标时间点矩阵分解特征； $\mathcal{F}_N$ 表示矩阵分解特征构造过程； A_s 表示源时间点邻接矩阵； A_t 表示目标时间点邻接矩阵。

7.10 矩阵分解特征如何标准化

矩阵分解特征是时间对特异的，所以标准化也按时间对做。对一个时间对，把源时间点特征和目标时间点特征上下合并，计算每个潜变量坐标的均值和标准差，然后分别标准化源与目标。

时间对内部标准化

$$\mu_k^{(s,t)} = \frac{1}{n_s + n_t} \left(\sum_{i=1}^{n_s} Z_{s|(s,t)}^{(N)}(i, k) + \sum_{j=1}^{n_t} Z_{t|(s,t)}^{(N)}(j, k) \right),$$

$$\widehat{Z}_{s|(s,t)}^{(N)}(i, k) = \frac{Z_{s|(s,t)}^{(N)}(i, k) - \mu_k^{(s,t)}}{\sigma_k^{(s,t)}}.$$

符号说明：这里 $\mu_k^{(s,t)}$ 表示时间对 (s, t) 内第 k 个矩阵分解坐标的均值； $\sigma_k^{(s,t)}$ 表示时间对 (s, t) 内第 k 个矩阵分解坐标的标准差； $Z_{s|(s,t)}^{(N)}(i, k)$ 表示源时间点第 i 个节点的第 k 个矩阵分解坐标； $Z_{t|(s,t)}^{(N)}(j, k)$ 表示目标时间点第 j 个节点的第 k 个矩阵分解坐标； $\widehat{Z}_{s|(s,t)}^{(N)}(i, k)$ 表示标准化后的源时间点坐标。目标时间点的标准化公式同理。

7.11 矩阵分解特征和其他表征如何组合

当实验只使用矩阵分解表征时，跨时间代价直接由 $\widehat{Z}_{s|(s,t)}^{(N)}$ 和 $\widehat{Z}_{t|(s,t)}^{(N)}$ 计算。当实验使用组合表征，例如表达加矩阵分解，或者矩阵分解加拉普拉斯，则对当前时间对进行拼接。

时间对上的组合特征

$$Z_{s|(s,t)}^{\text{combo}} = \left[\sqrt{\lambda_E} \widehat{Z}_s^{(E)}, \sqrt{\lambda_N} \widehat{Z}_{s|(s,t)}^{(N)}, \sqrt{\lambda_L} \widehat{Z}_s^{(L)}, \sqrt{\lambda_{SR}} \widehat{Z}_s^{(SR)} \right].$$

符号说明：这里 $Z_{s|(s,t)}^{\text{combo}}$ 表示为时间对 (s, t) 构造的源时间点组合特征； $\widehat{Z}_s^{(E)}$ 表示源时间点的标准化表达表征； $\widehat{Z}_{s|(s,t)}^{(N)}$ 表示源时间点在当前时间对上的标准化矩阵分解表征； $\widehat{Z}_s^{(L)}$ 表示源时间点的标准化拉普拉斯表征； $\widehat{Z}_s^{(SR)}$ 表示源时间点的标准化 SR 表征； λ_E 、 λ_N 、 λ_L 、 λ_{SR} 分别表示四类表征的非负权重；方括号表示按列拼接。

实际实验矩阵中通常不会一次性把四类全放进去，而是做单特征实验和两两组合实验。矩阵分解相关的组合包括表达加矩阵分解、矩阵分解加拉普拉斯、矩阵分解加 SR。

8 从特征到跨时间转移矩阵：三种机制

8.1 统一记号

对任意一个时间对 (s, t) ，假设已经得到源时间点的特征矩阵和目标时间点的特征矩阵。

源特征与目标特征

$$Z_s \in \mathbb{R}^{n_s \times d}, \quad Z_t \in \mathbb{R}^{n_t \times d}.$$

符号说明：这里 Z_s 表示源时间点所有单位的特征矩阵； Z_t 表示目标时间点所有单位的特征矩阵； n_s 表示源时间点单位数量； n_t 表示目标时间点单位数量； d 表示当前用于比较的特征维度。

8.2 余弦核：越同向，转移概率越大

余弦机制先计算两个特征向量之间的余弦距离，再把距离变成相似性核，最后按行归一化。

余弦距离与核

$$C_{ij} = 1 - \frac{\mathbf{z}_{s,i}^\top \mathbf{z}_{t,j}}{\|\mathbf{z}_{s,i}\|_2 \|\mathbf{z}_{t,j}\|_2}, \quad K_{ij} = \exp\left(-\frac{C_{ij}}{\tau}\right), \quad P_{ij} = \frac{K_{ij}}{\sum_{q=1}^{n_t} K_{iq}}.$$

符号说明：这里 $\mathbf{z}_{s,i}$ 表示源时间点第 i 个单位的特征向量； $\mathbf{z}_{t,j}$ 表示目标时间点第 j 个单位的特征向量； C_{ij} 表示源单位 i 与目标单位 j 的余弦距离； K_{ij} 表示由距离转成的非负相似性核； τ 表示温度参数，越小越偏向最近邻，越大越平滑； P_{ij} 表示最终行归一化后的转移概率； q 表示目标时间点中的另一个候选单位编号。

8.3 KL 核：把特征向量先变成分布再比较

KL 机制把每个单位的特征向量先变成一个概率分布，然后比较源分布和目标分布之间的信息差异。

特征向量的 softmax 分布

$$\pi_{s,i,k} = \frac{\exp(Z_s(i, k)/\beta)}{\sum_{a=1}^d \exp(Z_s(i, a)/\beta)}.$$

符号说明：这里 $\pi_{s,i,k}$ 表示源时间点第 i 个单位在第 k 个特征坐标上的概率； $Z_s(i, k)$ 表示源时间点第 i 个单位第 k 个原始特征值； β 表示 softmax 温度参数； a 表示特征坐标和索引； d 表示特征维度。

源特征分布到目标特征分布的 KL 代价

$$C_{ij}^{\text{KL}} = \sum_{k=1}^d \pi_{s,i,k} \log \frac{\pi_{s,i,k}}{\pi_{t,j,k}}.$$

符号说明：这里 C_{ij}^{KL} 表示源单位 i 到目标单位 j 的 KL 代价； $\pi_{s,i,k}$ 表示源单位 i 的第 k 个特征概率； $\pi_{t,j,k}$ 表示目标单位 j 的第 k 个特征概率； d 表示特征维度；对数项衡量目标分布是否能解释源分布。

8.4 稀疏半松弛最优传输：在局部候选边上做全局分配

稀疏最优传输先用余弦距离找候选边：每个源单位保留若干个代价最低的目标单位，每个目标单位也保留若干个来自源单位的近邻候选。然后只在这个稀疏候选图上做带熵正则的半松弛传输。

稀疏候选边集合

$$\mathcal{E}_{s,t} = \{(i,j) : j \in \text{TopK}_{\text{target}}(i)\} \cup \{(i,j) : i \in \text{TopK}_{\text{source}}(j)\}.$$

符号说明：这里 $\mathcal{E}_{s,t}$ 表示时间对 (s,t) 上保留下来的候选边集合； i 表示源单位； j 表示目标单位； $\text{TopK}_{\text{target}}(i)$ 表示对源单位 i 来说代价最低的若干目标单位； $\text{TopK}_{\text{source}}(j)$ 表示对目标单位 j 来说代价最低的若干源单位。

半松弛最优传输目标

$$\min_{T \geq 0} \sum_{(i,j) \in \mathcal{E}_{s,t}} T_{ij} C_{ij} + \varepsilon \sum_{(i,j) \in \mathcal{E}_{s,t}} T_{ij} (\log T_{ij} - 1) + \gamma D(T\mathbf{1} \parallel \mathbf{a}) \quad \text{s.t.} \quad T^\top \mathbf{1} = \mathbf{b}.$$

符号说明：这里 T 表示传输矩阵； T_{ij} 表示从源单位 i 分配到目标单位 j 的传输质量； C_{ij} 表示源单位 i 到目标单位 j 的代价； $\mathcal{E}_{s,t}$ 表示候选边集合； ε 表示熵正则强度； γ 表示源端质量松弛惩罚强度； $D(\cdot \parallel \cdot)$ 表示质量偏离惩罚； $\mathbf{1}$ 表示全 1 向量； $\mathbf{a}$ 表示源端先验质量，通常是均匀分布； $\mathbf{b}$ 表示目标端先验质量，通常也是均匀分布；约束 $T^\top \mathbf{1} = \mathbf{b}$ 表示目标端总质量要匹配目标先验。

求得传输矩阵后，还要把每一行归一化成转移概率。

传输矩阵到转移矩阵

$$P_{ij} = \frac{T_{ij}}{\sum_{q=1}^{n_t} T_{iq}}.$$

符号说明：这里 P_{ij} 表示源单位 i 到目标单位 j 的最终转移概率； T_{ij} 表示最优传输求得的原始传输质量； q 表示目标单位索引； n_t 表示目标时间点单位数量。

9 实验矩阵该怎么讲

9.1 单特征实验

单特征实验回答“单独依靠某一种信息，是否足以构造有意义的跨时间映射”。

实验类别	讲法
表达表征	只用表达模式判断早晚单位是否相似。它问的是分子状态能否解释跨时间对应。
拉普拉斯结构表征	只用图结构热核判断单位是否处在相似网络位置。它问的是网络拓扑位置能否解释跨时间对应。
发育潜能表征	只用 SR 判断发育状态是否相近。它问的是潜能状态能否解释跨时间对应。
矩阵分解表征	只用非负矩阵分解潜模块判断节点关系模式是否相似。它问的是网络潜模块能否解释跨时间对应。

9.2 两两组合实验

两两组合实验回答“信息源之间是否互补”。当前主要组合可以按下面方式讲。

组合	解释
表达 + 拉普拉斯	分子状态与网络结构位置是否互补。
表达 + SR	分子状态与发育潜能是否互补。
拉普拉斯 + SR	网络结构位置与发育潜能是否互补。
表达 + 矩阵分解	分子表达状态与网络潜模块是否互补。
矩阵分解 + 拉普拉斯	局部/模块式网络角色与谱扩散结构是否互补。
矩阵分解 + SR	网络潜模块与发育潜能是否互补。

9.3 三种构造 P 的后缀应该怎么解释

每一种单特征或组合特征，都可以接三种跨时间矩阵构造方式。

1. **余弦核**。先算余弦距离，再指数化，再行归一化；这是最直接的相似度基线。
2. **KL 核**。先把特征向量变成分布，再比较分布差异；适合强调“特征坐标相对组成”的解释。
3. **稀疏半松弛最优传输**。先选候选边，再在候选边上做全局传输分配；适合强调跨时间映射不是逐点贪心匹配，而是一个整体分配问题。

10 有效信息：为什么最后看宏观层减微观层

10.1 从转移矩阵到有效信息

转移矩阵 P 的每一行是一个源单位的未来去向分布。有效信息衡量的是：知道源单位是谁，能把目标单位的不确定性减少多少。

目标边缘分布

$$\bar{p}_j = \frac{1}{n_s} \sum_{i=1}^{n_s} P_{ij}.$$

符号说明：这里 $\bar{p}_j$ 表示目标单位 j 的平均到达概率； n_s 表示源时间点单位数量； P_{ij} 表示源单位 i 到目标单位 j 的转移概率；求和表示把所有源单位平均起来。

有效信息

$$\text{EI}(P) = H(\bar{\mathbf{p}}) - \frac{1}{n_s} \sum_{i=1}^{n_s} H(\mathbf{p}_{i\cdot}).$$

符号说明：这里 $\text{EI}(P)$ 表示转移矩阵 P 的有效信息； $H(\bar{\mathbf{p}})$ 表示目标边缘分布的熵； $\bar{\mathbf{p}}$ 表示由所有 $\bar{p}_j$ 组成的目标边缘分布向量； $\mathbf{p}_{i\cdot}$ 表示转移矩阵第 i 行，也就是源单位 i 的目标分布； $H(\mathbf{p}_{i\cdot})$ 表示第 i 行转移分布的熵； n_s 表示源单位数量。第一项越大，说明整体能覆盖多种目标状态；第二项越小，说明每个源单位的去向越确定。

10.2 有效信息增益

因果涌现关注的是：宏观层是否比微观层更有有效信息。如果宏观层的转移矩阵更清晰、更少噪声、更少一对多混乱，那么它的有效信息可能高于微观层。

有效信息增益

$$\Delta \text{EI}^{s \rightarrow t} = \text{EI}(P_{\text{macro}}^{s \rightarrow t}) - \text{EI}(P_{\text{micro}}^{s \rightarrow t}).$$

符号说明：这里 $\Delta \text{EI}^{s \rightarrow t}$ 表示从时间点 s 到时间点 t 的有效信息增益； $P_{\text{macro}}^{s \rightarrow t}$ 表示宏观层的跨时间转移矩阵； $P_{\text{micro}}^{s \rightarrow t}$ 表示微观层的跨时间转移矩阵； $\text{EI}(\cdot)$ 表示有效信息函数。若 $\Delta \text{EI}^{s \rightarrow t} > 0$ ，说明宏观层在该时间对上比微观层提供更多有效信息。

11 今天汇报时可以按这个顺序讲

11.1 建议讲述顺序

1. 先说总问题：我们要为早晚时间点的同一层级单位构造转移矩阵 P 。
2. 再说 Light CCI：基因层是 GRN，spot/domain 层是 CCI，每层每时间点先变成图。
3. 再说四类表征：表达看状态，拉普拉斯看结构位置，SR 看发育潜能，联合非负矩阵分解看网络潜模块。

4. 然后说三种 P 构造方式：余弦核、KL 核、稀疏最优传输。
5. 最后说有效信息：比较宏观层和微观层的 EI，看宏观层是否更有确定性和选择性。

11.2 每一块的一句话总结

部分	一句话
Light CCI	每个层级用最符合生物语义的关系图：基因用 GRN, spot/domain 用 CCI。
表达表征	单位是否相似，首先可以看它们的表达状态是否相似；基因层看基因在 spot 上的表达模式。
拉普拉斯表征	单位是否相似，也可以看它们在关系图上的扩散结构位置是否相似。
SR 表征	单位是否相似，还可以看它们的发育潜能是否相近；基因级 SR 由表达加权分配得到。
矩阵分解表征	单位是否相似，还可以看它们在网络中属于哪些潜在模块；spot 层用共享核心有向分解。
转移矩阵	特征越相似或传输代价越低，早期单位转移到晚期单位的概率越大。
有效信息	如果宏观层的转移更确定、更有选择性，那么宏观层会产生正的有效信息增益。

12 可能被问到的问题与回答

12.1 为什么 Light CCI 里面基因层不用 CCI？

因为 CCI 描述的是细胞、spot 或 domain 之间的配体-受体通讯，而基因层的节点是基因。基因之间更自然的关系是调控关系，即 GRN。因此基因层用 GRN，spot/domain 层用 CCI。

12.2 为什么表达表征在基因层要用基因乘 spot 矩阵？

如果每个基因只有一个平均表达量，那么基因层特征几乎没有几何结构。把一个基因在所有 spot 上的表达模式作为特征，相当于描述“这个基因在哪里表达、以什么空间模式表达”。这比一个标量更有信息量。

12.3 为什么拉普拉斯表征要用热核签名而不是直接用邻接行？

邻接行太稀疏，也太依赖具体节点编号。热核签名描述的是节点在图扩散过程中的多尺度结构位置，更像结构指纹。它既保留局部邻域信息，也保留较全局的图结构信息。

12.4 SR 给基因的公式会不会是在算相关性？

不是。基因级 SR 是表达加权平均。公式是“每个 spot 的 SR 乘以该 spot 中该基因的表达量，再除以该基因总表达量”。它表达的是这个基因主要在哪些发育状态的 spot 中表达，而不是两个向量的相关系数。

12.5 为什么矩阵分解表征要对每个时间对单独做？

因为矩阵分解表征是为了服务某一个具体的跨时间映射。对 (s, t) 单独分解，可以让这两个时间点共享一套潜模块坐标，同时避免不同时间点节点数量不一致带来的全局对齐问题。尤其 spot 层，早晚 spot 数常常不同，因此不能简单地要求所有时间点共享同一列空间。

12.6 普通联合非负矩阵分解和共享核心有向分解有什么区别？

普通联合分解写作 $A_s \approx W_s H$ 、 $A_t \approx W_t H$ ，它要求两张矩阵列数一致，节点特征是 W 的行。共享核心有向分解写作 $A_s \approx U_s B V_s^\top$ 、 $A_t \approx U_t B V_t^\top$ ，它允许两张方阵大小不同，节点特征是出边角色 U 和入边角色 V 的拼接。

12.7 为什么稀疏最优传输比简单余弦核更强？

余弦核是每个源单位独立看目标相似度；稀疏最优传输是在候选边上做整体分配。它会考虑目标端质量约束和全局竞争，因此更像“所有早期单位一起分配到晚期单位”的过程，而不是每个源单位各算各的。

13 一页口头版总结

核心结论

今天这套方法可以用一句话讲清楚：我们先把每个时间点、每个层级表示成一张符合生物语义的关系图；基因层是 GRN，spot 和 domain 层是 CCI。然后我们从不同角度给每个单位构造特征：表达表征描述分子状态，拉普拉斯热核描述网络结构位置，SR 描述发育潜能，联合非负矩阵分解描述网络潜模块。给定任意早晚时间点，我们用这些特征构造源单位到目标单位的转移矩阵 P 。最后用有效信息衡量这个转移矩阵有多确定、有多有选择性，并比较宏观层和微观层。如果宏观层的有效信息更高，就说明宏观尺度比微观尺度更好地组织了跨时间发育映射，这就是我们要观察的因果涌现信号。